

解构革命:为现代LLM爱好者准备的“Attention Is All You Need”图解指南

第一部分:搭建舞台 - Transformer之前的世界

为了充分理解2017年那篇石破天惊的论文《Attention Is All You Need》所带来的革命性影响,我们必须首先回到那个由不同技术范式主导的时代。对于任何一位有志于投身大语言模型(LLM)领域的新人而言,理解Transformer旨在解决的“问题”与理解其“解决方案”本身同等重要。本部分将围绕2017年之前占主导地位的技术——循环神经网络(RNN)的局限性展开叙述,为Transformer的登场铺设好舞台。

语言与序列的挑战

教机器理解人类语言的根本困难在于上下文和顺序。语言远非简单的“词袋”;词语的排列顺序和它们之间的相互关系共同构成了意义。一个简单的例子,“狗咬人”与“人咬狗”,词语相同,但顺序的颠倒彻底改变了语义。这种按顺序排列的数据被称为“序列数据”,它不仅包括自然语言,还涵盖了时间序列数据、语音和DNA序列等,这突显了序列模型的广泛适用性¹。

因此,任何人工智能模型面临的核心挑战是:它如何在处理一个词的同时,记住由句子或段落中较早出现的词所提供的上下文?这就引出了一个关键概念——“长距离依赖”(long-range dependencies)。模型必须有能力在序列中跨越很长的距离建立联系,才能真正理解其内在逻辑²。

循环神经网络(RNN)与长短期记忆网络(LSTM)的统治

为了应对序列挑战,研究人员开发了循环神经网络(RNN)。我们可以将RNN比作一个逐字

阅读句子的人。在每一步，这个人都会保留一个“记忆”或“隐藏状态”(即对已读内容的总结)，并将其与当前读到的词相结合，以更新自己的理解⁴。这个过程是天生串行的，一步紧跟一步。

然而，标准的RNN存在一个致命缺陷：它们的“记忆力”很差，像一个记性不好的人，读到后面就忘了前面。为了解决这个问题，一种更先进的变体——长短期记忆网络(LSTM)应运而生。LSTM被设计用来专门解决长期依赖问题¹。我们可以将其内部机制想象成一条“传送带”(即单元状态)和三个精密的“门”(遗忘门、输入门和输出门)。这些门结构允许模型智能地决定哪些信息需要从记忆中丢弃，哪些新信息需要添加，以及在当前步骤需要输出哪些信息。这种设计使得LSTM在记住长距离信息方面远胜于普通RNN⁷。

在Transformer问世之前，LSTM及其简化版门控循环单元(GRU)是序列建模任务(如机器翻译)公认的最先进技术，这一点在《Attention Is All You Need》的引言中也得到了承认⁹。

根基上的裂痕

尽管LSTM取得了巨大成功，但它依然建立在循环这一基本范式之上，而这个根基存在两个无法通过修补来解决的根本性缺陷。正是这两个缺陷，激励着整个领域去寻找一种全新的替代方案。

问题一：“遗忘”问题(梯度消失)

即便有了LSTM精巧的门控机制，当信息在长序列的“链条”上传递时，来自早期词语的信号(在训练中体现为梯度)仍然会随着层层传递而逐渐稀释，最终变得微乎其微，这个现象被称为“梯度消失”问题³。

让我们来看一个具体的例子。在处理句子“那个住在街角蓝色大房子里，并且几十年来一直是社区组织者的男人，他很开心”(The man who lives in the big blue house on the corner, and who has been a community organizer for decades, is happy)时，模型需要将动词“is”与主语“man”联系起来，以确定正确的单数形式。对于RNN或LSTM来说，当模型处理到句末的“is”时，关于句首“man”是单数名词的这个关键信息可能已经在长长的信息传递链中被“遗忘”了，导致模型难以做出正确的语法判断¹。

问题二：并行化瓶颈

RNN最致命的弱点在于其固有的顺序性。由于对第t个词的计算依赖于第t-1个词的计算结果，因此无法同时处理句子中的所有词语³。

这个限制可以用一个生动的比喻来解释：这就像一条汽车装配线，你必须完全装好上一个零件，才能开始下一个零件的装配工作。你无法让多个工人同时在汽车的不同部分施工。在那个计算能力（尤其是GPU的并行计算能力）飞速发展的时代，这种串行瓶颈使得在海量数据集上训练大型模型变得极其缓慢和低效，成为人工智能发展的巨大障碍⁵。

RNN/LSTM范式的核心矛盾在于，其最大的优点（天生能够处理序列顺序）也正是其最大的缺点（强制性的串行计算）。整个领域试图用更复杂的门控机制（如LSTM）来修补“遗忘”问题，但只要不放弃“循环”这个基本思想，就无法解决根本性的速度和并行化瓶颈。

《Attention Is All You Need》这篇论文的革命性之处在于，它不仅仅是提出了一个更好的组件，而是提出了一个全新的架构。这个架构做出了一个大胆的权衡：为了实现大规模并行化，牺牲了内置的序列处理能力，然后通过一种创新的方式（即位置编码）重新解决了顺序问题。这是一个范式级的飞跃。

为了更清晰地展示这种范式转变，下表总结了两种架构的根本区别。

特性	循环神经网络 (RNN/LSTM)	Transformer
核心机制	循环(逐步处理)	注意力(一次性建立关系)
序列处理	串行(一次一个词元)	并行(一次所有词元)
长距离依赖	易受梯度消失影响(困难)	通过注意力直接连接(路径长度为1, 容易)
训练速度	慢(受序列长度限制)	快(高度可并行化)
词序知识	架构固有	通过位置编码显式添加

第二部分：Transformer的架构 - 逐个组件剖析

这部分是本指南的核心。我们将深入Transformer的内部，像拆解一台精密机器一样，逐一剖析其关键组件。我们将使用生动的类比和分步解释，不仅说明每个部分“如何”工作，更要揭示其“为何”如此设计。

核心突破：自注意力机制(Self-Attention)

自注意力机制是Transformer的心脏，是它能够在没有循环结构的情况下理解上下文的引擎。其核心思想是，允许句子中的每个词“审视”所有其他词，并根据当前上下文动态地判断哪些词对自身的意义最为重要¹¹。它用一个全连接的关系网络取代了RNN的顺序记忆。

鸡尾酒会类比

想象你身处一个嘈杂的鸡尾酒会，周围同时进行着多场对话。你的大脑(模型)可以专注于某一场对话(一个词)，但如果房间另一头有人提到了你的名字(一个相关的词)，你的注意力会立即被吸引过去。自注意力机制就是这种动态的、依赖于上下文的专注能力¹⁴。

QKV框架：图书馆查询系统

为了实现这种专注能力，自注意力机制引入了一个名为Query-Key-Value(查询-键-值，简称QKV)的框架。我们可以把它比作一个先进的图书馆查询系统¹⁴：

- **查询(Query, Q)**：代表当前词的需求。比如，当模型处理代词“it”时，它会生成一个Query，相当于在问：“我，‘it’，到底指的是什么？”¹³。
- **键(Key, K)**：句子中的每个词都拥有一个Key，就像书架上每本书的书脊上贴的标签。在句子“The animal didn't cross the street because **it** was too tired”中，“animal”这个词的Key可能会标识：“我是一个潜在的指代对象”。而“street”的Key则标识：“我是一个地点”¹³。
- **值(Value, V)**：每个词还拥有一个Value，代表这个词的实际内容或深层含义。比如，“animal”的Value就是“动物这个概念本身”¹³。

工作流程详解

自注意力机制的计算过程可以分解为以下几个优雅的步骤：

1. 输入嵌入：首先，句子中的每个词被转换成一个向量，称为词嵌入(embedding)。这个向量是词语含义的数学表示¹²。
2. 生成 Q, K, V ：对于每个词的嵌入向量，我们通过将其分别乘以三个独立且可训练的权重矩阵(W_q, W_k, W_v)，来生成三个新的向量：Query向量、Key向量和Value向量¹²。这是至关重要的一步，因为模型正是在这里学习如何提出有效的“问题”(Query)和如何设计信息丰富的“标签”(Key)。
3. 第一步：计算得分(点积)：为了确定“it”(作为Query)应该对“animal”(作为一个Key)投入多少注意力，模型会计算这两个向量的点积(dot product)。点积得分越高，意味着相关性越强¹²。这个过程会对每个词的Query与所有其他词的Key进行计算，从而得到一个注意力得分矩阵。
4. 第二步：缩放与Softmax：得到的原始得分会除以一个缩放因子(通常是Key向量维度的平方根， $\sqrt{d_k}$)，这一步是为了在训练过程中保持梯度稳定。然后，将缩放后的得分输入到一个Softmax函数中。Softmax函数会将这些得分转换成一个概率分布，所有得分的和为1¹²。经过这一步，对于“it”这个词，它对“animal”的注意力权重可能是0.85，对“street”是0.10，对其他词是更小的值。
5. 第三步：加权求和：最后，模型会计算所有词的Value向量的加权和，而这个“权”，就是上一步计算出的注意力权重。因此，“it”这个词的新表示就变成了：
 $0.85 \times V_{\text{animal}} + 0.10 \times V_{\text{street}} + \dots$ 。通过这个过程，“it”的向量表示吸收了它最相关词语“animal”的含义，从而在数学上理解了指代关系¹⁵。

这种QKV机制不仅仅是一个相似度搜索，它是一个完全可学习、可微分(即可通过梯度下降进行训练)的信息检索系统。权重矩阵 W_q, W_k 和 W_v 并非固定不变，而是在训练过程中不断优化的。这意味着模型不仅仅是在匹配预设的查询和键，它在学习如何为特定任务(如翻译或情感分析)构建最优的查询、键和值表示。例如，对于翻译任务，模型可能会学到名词的性别是其代词Query需要关注的一个重要Key。整个过程是平滑且可微的，使得反向传播能够调整这些权重，让模型自己学会“相关性”到底意味着什么。这是一种从硬编码逻辑到学习动态相关性的深刻转变¹²。

获得更丰富的视角：多头注意力机制(Multi-Head Attention)

如果说单头自注意力机制是一位专家，那么多头注意力机制就是邀请了一个专家委员会，

从不同角度共同审视同一个问题，从而得出更全面、更深刻的结论。

“专家委员会”类比

想象一下，一个专家委员会正在评估一栋房子¹⁴。委员会中有多位专家，每个人都有自己的专长：

- 一位是结构工程师，他关注的是句子的语法结构、主谓宾关系。
- 一位是历史学家，他关注的是词语的语义关联和概念层面的联系。
- 一位是侦探，他专门负责追踪代词（如“he”、“it”）的指代关系¹⁶。

单凭任何一位专家的意见都可能片面，但综合所有专家的报告，就能对这栋房子（这个句子）有一个立体而深入的理解。

工作机制

多头注意力机制正是以这种“分而治之”的方式工作的：

1. 划分焦点：模型不会只学习一组大的 W_q, W_k, W_v 权重矩阵，而是学习多组（例如，论文中是8组）更小的权重矩阵。输入的词嵌入向量的维度会被平均分配给每个“头”（Head）¹⁶。
2. 并行注意力计算：每个头在自己的“专业领域”（即分配到的子空间）内，独立地进行完整的自注意力计算（生成QKV、计算得分、Softmax、加权求和）。这些计算是完全并行的，因此在计算上非常高效²¹。每个头都会输出一个结果向量，代表它自己的“专家意见”。
3. 整合与投射：所有头的输出向量会被拼接（concatenate）在一起，形成一个大的向量。然后，这个大向量会再乘以一个最终的、可学习的权重矩阵 W_o 。这个最终的线性投射层就像是委员会的主席，它学习如何最好地整合所有专家的不同意见，形成一个统一、丰富的最终结论²¹。

多头注意力本质上是一种内置于网络层中的高效集成学习（ensemble learning）。它允许模型在不同的“表示子空间”中同时捕捉不同类型的依赖关系。其强大之处在于，每个头都可以专注于学习一种特定模式（如语法、语义、位置关系等），而模型最终学会了如何智能地组合这些专业化的视角。这种“分而治之，再总而合之”的策略，为模型提供了比单头注意力远为丰富和稳健的表示能力，显著提升了模型的泛化能力，并防止其过度依赖某一种单一

的关系模式¹⁹。

重新引入秩序:位置编码(Positional Encoding)

在拥抱了并行的注意力机制后, Transformer也付出了代价:它失去了对词语顺序的天然感知能力。如果没有补救措施, 对于模型来说, “猫坐在垫子上”和“垫子坐在猫上”将毫无区别, 因为自注意力机制像一个“词袋”模型, 平等地看待所有词, 而忽略了它们的排列²⁴。

简单的方案及其缺陷

一个最直接的想法是给每个词分配一个数字索引(1, 2, 3,...)。但这种方法存在明显问题:对于长句子, 索引值会变得非常大;而且对于不同长度的句子, 这些索引的尺度不一, 使得模型难以泛化²⁵。

精妙的正弦波方案

论文的 authors 提出了一种极为巧妙的解决方案:使用不同频率的正弦(sine)和余弦(cosine)函数来为位置编码²⁴。其工作原理如下:

- 对于序列中的每一个位置(例如, 第1个词, 第2个词...), 都生成一个独一无二的向量。
- 这个位置编码向量的维度与词嵌入向量的维度完全相同(例如, 512维)。
- 在这个向量的每个维度上, 都使用一个不同频率的正弦或余弦函数来计算其值。
- 最后, 将生成的位置编码向量与对应词的词嵌入向量相加²⁷。这样得到的最终向量, 既包含了词语的语义信息(来自词嵌入), 也包含了词语的位置信息(来自位置编码)。

选择正弦和余弦函数并非偶然, 这是一个数学上的神来之笔。这种方法不仅为每个绝对位置提供了独特的编码, 更重要的是, 它使得模型能够极其容易地学习相对位置关系。一个关键的数学特性是, 任意位置 $pos + k$ 的编码, 都可以表示为位置 pos 编码的一个线性函数(具体来说是一个旋转)。由于注意力机制的核心运算就是一系列线性变换(矩阵乘法), 模型因此可以毫不费力地学会诸如“左边第2个词”或“紧邻的下一个词”这类相对关系。这使得模型能够泛化到训练时未见过的更长的句子, 因为相对位置的模式是保持不变的²⁵。这套

编码方案就像是为无序的词语世界引入了一个平滑、连续且可学习的坐标系。

幕后英雄:残差连接与层归一化(Add & Norm)

在Transformer的结构图中,每个子层(如多头注意力和前馈网络)旁边都有一个“Add & Norm”模块。这两个组件是训练深度Transformer模型的无名英雄,没有它们,由数十甚至上百个层堆叠而成的现代LLM将难以训练。

深度网络的挑战

Transformer通过堆叠许多层来增强其能力(原论文中是6层,而现代模型如GPT-3有96层)。然而,训练非常深的网络是出了名的困难,因为梯度在反向传播过程中穿过太多层后,容易变得过小(梯度消失)或过大(梯度爆炸),导致训练失败²⁹。

残差连接("Add")

残差连接,也称“跳跃连接”(skip connection),是一种简单而强大的技术。它将一个层的输入直接加到这个层的输出上²⁹。

我们可以将其比作在复杂的城市道路(通过注意力层进行变换)旁边修建了一条**“信息高速公路”**。原始的、未经修改的信息可以通过这条高速公路直接传递到下一层,而主路则负责学习对信息的复杂变换。这样确保了即使深层网络中的某些层没有学到有用的东西,原始信息也不会丢失³²。

层归一化("Norm")

层归一化紧跟在残差连接之后。它将“Add”操作后的结果进行标准化处理,即调整每个样本在这一层输出的向量,使其均值为0,标准差为1。

这就像一个流量调节器，确保在网络中流动的数据不会因为逐层累加而变得过大或过小，从而稳定了训练过程，并常常能加速收敛²⁹。

残差连接和层归一化之间存在一种共生关系。残差连接改变了每一层学习的根本任务：它不再需要从零开始学习一个完整的、复杂的变换，而只需要学习对恒等函数（即输入）的修正或残差。如果一个层学不到任何有用的东西，它可以简单地输出零，让信息通过“高速公路”无损通过，这极大地简化了学习问题。然而，连续的加法操作可能导致输出值的尺度失控。此时，层归一化就介入了，它在每个“Add”步骤后重新校准数值范围，确保下一层的输入是“行为良好”的²⁹。这种设计是构建和稳定训练极深网络的关键所在。

第三部分：组装机及其不朽遗产

在剖析了所有核心组件之后，现在让我们退后一步，看看它们如何组装成一台完整的机器，并追溯这篇论文如何催生了现代LLM的两大主流家族：BERT和GPT。

完整蓝图：编码器-解码器堆栈

《Attention Is All You Need》论文提出的完整Transformer架构，是为其最初的目标任务——机器翻译而设计的。它由两个主要部分组成：一个编码器(Encoder)和一个解码器(Decoder)³⁵。

- 编码器的任务：编码器的职责是“阅读”并“理解”输入句子（例如，一句英文）。它由我们前面讨论过的多个结构相同的层堆叠而成（每层包含多头注意力和前馈网络），最终输出一系列富含上下文信息的数字表示（向量）³⁶。
- 解码器的任务：解码器的职责是接收编码器输出的数字表示，并逐字生成目标句子（例如，德语）。它也由类似的层堆叠而成，但有一个关键区别：解码器层内部除了有自注意力机制外，还有一个额外的**“编码器-解码器注意力”**机制。这个机制允许解码器在生成每个新词时，能够“关注”输入句子的所有部分，从而实现准确翻译²²。

整个机器翻译过程大致如下：英文句子“How are you?”被送入编码器，生成一组丰富的上下文向量。然后，解码器开始生成过程，它首先生成第一个德语词“Wie”，接着，它将“Wie”和编码器的上下文向量作为输入，生成下一个词“geht”，如此循环，直到生成代表句子结束的特殊标记为止³⁶。

伟大的分歧:BERT与GPT的诞生

Transformer的发布开启了一个新时代。很快,研究人员意识到,对于许多非翻译任务,并不总是需要完整的编码器-解码器结构。有时,只使用其中一半不仅足够,甚至效果更好。这一发现导致了Transformer架构的“大分歧”,催生了两个最著名的LLM家族³⁸。

BERT:作为理解大师的编码器

- 架构:BERT(Bidirectional Encoder Representations from Transformers)只使用了原始Transformer的**编码器(Encoder)**部分³⁸。
- 核心特性(双向注意力):作为编码器, BERT的自注意力机制是双向的。在处理句子中的任何一个词时,它都能同时“看到”这个词左边和右边的所有词。这赋予了它对上下文深刻而全面的理解能力³⁵。
- 训练与应用:BERT的典型预训练任务是“掩码语言模型”(Masked Language Modeling),即随机遮盖句子中的一些词(例如,“猫坐在子上”),然后训练模型去预测被遮盖的词。这种训练方式迫使BERT去深入理解双向语境。因此, BERT成为了一个语言理解的专家,在文本分类、情感分析、命名实体识别和问答等任务上表现卓越⁴⁰。简而言之, BERT是一个分析器。

GPT:作为多产作家的解码器

- 架构:GPT(Generative Pre-trained Transformer)则只使用了原始Transformer的**解码器(Decoder)**部分³⁸。
- 核心特性(因果/掩码注意力):作为为生成任务设计的解码器, GPT的自注意力机制是因果的(Causal)或称带掩码的(Masked)。这意味着在预测下一个词时,它只能看到已经生成的词,而不能“偷看”未来的词。这确保了其生成过程的合理性³⁸。
- 训练与应用:GPT的预训练任务非常直观:预测文本序列中的下一个词。这种从左到右的自回归训练方式,使其成为一个语言生成的专家。它擅长创作连贯、自然的文本,因此在创意写作、文章摘要、对话式AI(聊天机器人)等任务中大放异彩⁴⁰。简而言之, GPT是一个

生成器。

这种架构上的选择(编码器-only vs. 解码器-only)并非偶然，它与模型的预训练策略和最终涌现出的能力紧密相连。BERT的目标是获得最佳的词语表示，这需要完整的上下文，因此双向的编码器是自然之选，其理想的训练任务(MLM)也充分利用了这一特性。而GPT的目标是生成文本，这是一个逐词进行的自回归过程，因此只能看到过去信息的因果解码器是其不二之选，其训练任务(下一个词预测)也完美地模拟了这一过程。这种优雅的分野，展示了《Attention Is All You Need》中提出的组件是何等的灵活与强大，它们成为了后续所有LLM创新的基石。

下表为新入门者提供了一个清晰的指南，以辨别当今主流的Transformer架构。

架构	核心特性	著名范例	主要应用场景
仅编码器 (Encoder-Only)	双向自注意力	BERT, RoBERTa, FinBERT	语言理解 (文本分类, 命名实体识别, 情感分析)
仅解码器 (Decoder-Only)	因果(掩码)自注意力	GPT系列, LLaMA, Mistral	语言生成 (聊天机器人, 创意写作, 摘要)
编码器-解码器 (Encoder-Decoder)	完整的双向编码器 + 带交叉注意力的因果解码器	原始Transformer, T5, BART	序列到序列 (机器翻译, 摘要)

结论:为何注意力(依然)是你所需的一切

《Attention Is All You Need》这篇论文的标题在今天看来，既是大胆的宣言，也是精准的预言。它所引入的Transformer架构，通过解决RNN的两个根本性顽疾——串行计算瓶颈和长距离依赖学习困难——彻底改变了自然语言处理的版图。

其核心贡献并不仅仅是提出了一种名为“自注意力”的新颖机制，更重要的是，它展示了如何围绕这一机制构建一个完全并行的架构。正是这种并行特性，释放了现代硬件(如GPU和TPU)的巨大潜力，使得在过去难以想象的庞大数据集上训练规模空前的模型成为可能。这直接开启了我们今天所处的大语言模型时代。

从BERT对语言的深刻理解，到GPT系列流畅自然的文本生成，几乎所有自2017年以来在人工智能领域的重大突破，都根植于这篇论文所奠定的架构基础之上。它为整个领域提供了

一套强大、灵活且可扩展的构建模块。因此，当我们回望这场AI革命的起点时，会发现其核心驱动力确实源于一个简单而深刻的理念：注意力，就是你所需要的一切³⁵。

Works cited

1. Long Short-Term Memory (LSTM) Networks: Modeling Long-Term Dependencies - Medium, accessed July 27, 2025, <https://medium.com/@sruthy.sn91/long-short-term-memory-lstm-networks-modeling-long-term-dependencies-8ad6ec8582f8>
2. Chapter 8 Attention and Self-Attention for NLP | Modern Approaches in Natural Language Processing, accessed July 27, 2025, https://slds-lmu.github.io/seminar_nlp_ss20/attention-and-self-attention-for-nlp.html
3. Transformer vs RNN in NLP: A Comparative Analysis - Appinventiv, accessed July 27, 2025, <https://appinventiv.com/blog/transformer-vs-rnn/>
4. RNN vs Transformer: A Deep Dive from Fundamentals to Applications | by Shawn - Medium, accessed July 27, 2025, <https://medium.com/@hexiangnan/rnn-vs-transformer-a-deep-dive-from-fundamentals-to-applications-ee4d700dd152>
5. From RNNs to Transformers | Baeldung on Computer Science, accessed July 27, 2025, <https://www.baeldung.com/cs/rnns-transformers-nlp>
6. Understanding LSTM Networks - Colah's Blog, accessed July 27, 2025, <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
7. Long short-term memory - Wikipedia, accessed July 27, 2025, https://en.wikipedia.org/wiki/Long_short-term_memory
8. What is LSTM - Long Short Term Memory? - GeeksforGeeks, accessed July 27, 2025, <https://www.geeksforgeeks.org/deep-learning/deep-learning-introduction-to-long-short-term-memory/>
9. Attention Is All You Need, accessed July 27, 2025, <https://arxiv.org/pdf/1706.03762>
10. Lecture 14: Learning Long-Term Dependencies, accessed July 27, 2025, https://www.cs.toronto.edu/~rgrosse/courses/csc421_2019/readings/L14%20Exploding%20and%20Vanishing%20Gradients.pdf
11. What is self-attention? | IBM, accessed July 27, 2025, <https://www.ibm.com/think/topics/self-attention>
12. Understanding and Coding the Self-Attention Mechanism of Large ..., accessed July 27, 2025, <https://sebastianraschka.com/blog/2023/self-attention-from-scratch.html>
13. A Beginner's Guide to Self-Attention in Transformers | by Nacho Zobian | Medium, accessed July 27, 2025, <https://medium.com/@nachozobian/a-beginners-guide-to-self-attention-in-transformers-baf71a971efd>
14. Understanding Attention in Transformers: A Visual Guide | by Nitin Mittapally | Medium, accessed July 27, 2025, <https://medium.com/@nitinmittapally/understanding-attention-in-transformers-a>

[-visual-guide-df416bfe495a](#)

15. Explained: Multi-head Attention (Part 1) - Erik Storrs, accessed July 27, 2025, <https://storrs.io/attention/>
16. Multi-headed Attention the mathematical meaning - DeepLearning.AI, accessed July 27, 2025, <https://community.deeplearning.ai/t/multi-headed-attention-the-mathematical-meaning/346228>
17. Understanding the Self-Attention Mechanism in 8 min - YouTube, accessed July 27, 2025, <https://www.youtube.com/watch?v=W28LfOld44Y>
18. Understanding The Attention Mechanism In Transformers: A 5-minute visual guide. - Reddit, accessed July 27, 2025, https://www.reddit.com/r/compsci/comments/1cjc318/understanding_the_attention_mechanism_in/
19. Understanding Self-Attention and Multi-Head Attention in Transformers - Medium, accessed July 27, 2025, <https://medium.com/@manaswink/understanding-self-attention-and-multi-head-attention-in-transformers-3464370abb31>
20. What is different in each head of a multi-head attention mechanism? - AI Stack Exchange, accessed July 27, 2025, <https://ai.stackexchange.com/questions/25148/what-is-different-in-each-head-of-a-multi-head-attention-mechanism>
21. 11.5. Multi-Head Attention — Dive into Deep Learning 1.0.3 documentation, accessed July 27, 2025, https://d2l.ai/chapter_attention-mechanisms-and-transformers/multihead-attention.html
22. Transformers Explained Visually (Part 3): Multi-head Attention, deep dive, accessed July 27, 2025, <https://towardsdatascience.com/transformers-explained-visually-part-3-multi-head-attention-deep-dive-1c1ff1024853/>
23. Exploring Multi-Head Attention: Why More Heads Are Better Than One | by Hassaan Idrees, accessed July 27, 2025, <https://medium.com/@hassaanidrees7/exploring-multi-head-attention-why-more-heads-are-better-than-one-006a5823372b>
24. Positional Encoding in Transformers - GeeksforGeeks, accessed July 27, 2025, <https://www.geeksforgeeks.org/nlp/positional-encoding-in-transformers/>
25. A Gentle Introduction to Positional Encoding in Transformer Models ..., accessed July 27, 2025, <https://machinelearningmastery.com/a-gentle-introduction-to-positional-encoding-in-transformer-models-part-1/>
26. Transformer Architecture: The Positional Encoding - Amirhossein Kazemnejad's Blog, accessed July 27, 2025, https://kazemnejad.com/blog/transformer_architecture_positional_encoding/
27. Positional Encoding in the Transformer Model | by Sandaruwan Herath - Medium, accessed July 27, 2025, <https://medium.com/image-processing-with-python/positional-encoding-in-the->

- [transformer-model-e8e9979df57f](#)
28. Positional Encoding Explained: A Deep Dive into Transformer PE - Medium, accessed July 27, 2025, <https://medium.com/thedeephub/positional-encoding-explained-a-deep-dive-into-transformer-pe-65cfe8cfe10b>
 29. Normalization and Residual Connections in Generative AI - Tutorials Point, accessed July 27, 2025, <https://www.tutorialspoint.com/gen-ai/normalization-and-residual-connections.htm>
 30. Why Are Residual Connections Important in Transformer Architectures? | Baeldung on Computer Science, accessed July 27, 2025, <https://www.baeldung.com/cs/transformer-networks-residual-connections>
 31. Mastering Residual Connections: Enhancing Neural Networks for Optimal Performance, accessed July 27, 2025, <https://www.lunartech.ai/blog/mastering-residual-connections-enhancing-neural-networks-for-optimal-performance>
 32. Do Transformers Really Need Residual Connections? : r/deeplearning - Reddit, accessed July 27, 2025, https://www.reddit.com/r/deeplearning/comments/1gky088/do_transformers_really_need_residual_connections/
 33. Why are residual connections needed in transformer architectures? - Cross Validated, accessed July 27, 2025, <https://stats.stackexchange.com/questions/565196/why-are-residual-connections-needed-in-transformer-architectures>
 34. On Layer Normalization in the Transformer Architecture - arXiv, accessed July 27, 2025, <https://arxiv.org/pdf/2002.04745>
 35. BERT Vs GPT-4: Evolution Of Transformer Model - Xonique, accessed July 27, 2025, <https://xonique.dev/blog/the-evolution-of-transformer-models-in-nlp/>
 36. How Transformers Work: A Detailed Exploration of Transformer Architecture - DataCamp, accessed July 27, 2025, <https://www.datacamp.com/tutorial/how-transformers-work>
 37. Multi-Head Attention and Transformer Architecture - Pathway, accessed July 27, 2025, <https://pathway.com/bootcamps/rag-and-llms/coursework/module-2-word-vectors-simplified/bonus-overview-of-the-transformer-architecture/multi-head-attention-and-transformer-architecture/>
 38. Transformer Architectures: Encoder Vs Decoder-Only | by Mandeep Singh - Medium, accessed July 27, 2025, <https://medium.com/@mandeep0405/transformer-architectures-encoder-vs-decoder-only-fea00ae1f1f2>
 39. Why use decoders only (gpt) when we have full transformers architecture? - Reddit, accessed July 27, 2025, https://www.reddit.com/r/deeplearning/comments/1jbacim/why_use_decoders_only_gpt_when_we_have_full/
 40. GPT vs BERT Explained : Transformer Variations & Use Cases Simplified - YouTube,

- accessed July 27, 2025, <https://www.youtube.com/watch?v=AprUD-TSUYE>
41. GPT Vs. BERT: A Technical Deep Dive | AI Rafay Global, accessed July 27, 2025, <https://alrafayglobal.com/gpt-vs-bert/>
 42. 10 Things You Need to Know About BERT and the Transformer Architecture That Are Reshaping the AI Landscape, accessed July 27, 2025, <https://neptune.ai/blog/bert-and-the-transformer-architecture>
 43. BERT vs. GPT: What's the Difference? - Coursera, accessed July 27, 2025, <https://www.coursera.org/articles/bert-vs-gpt>
 44. Comparison of BERT vs GPT - arXiv, accessed July 27, 2025, <https://arxiv.org/pdf/2405.12990>
 45. GPT and BERT: A Comparison of Transformer Architectures - DEV Community, accessed July 27, 2025, <https://dev.to/meetkern/gpt-and-bert-a-comparison-of-transformer-architectures-2k46>
 46. Impact of Transformer-Based Models in NLP: An In-Depth Study on BERT and GPT, accessed July 27, 2025, https://www.researchgate.net/publication/384984757_Impact_of_Transformer-Based_Models_in_NLP_An_In-Depth_Study_on_BERT_and_GPT