

AI之眼如何演进：一篇“小白”也能看懂的动态注意力技术解析报告

第一部分：故事的开端——AI看图遇到了什么麻烦？

第一节 “变形金刚”跨界做视觉，优点和缺点同样突出

最近几年，人工智能(AI)领域发生了一场巨变。一个最初为理解语言(比如做翻译、写文章)而设计的强大模型，名叫Transformer(我们暂且叫它“变形金刚”)，被发现有惊人的潜力¹。于是，科学家们把它“跨界”用到了计算机视觉领域，教AI看懂图片。就这样，视觉变形金刚(Vision Transformer, ViT)诞生了，它彻底改变了AI看图的方式，甚至挑战了传统方法(CNN)十多年的霸主地位¹。

ViT看图的方法很特别。它不像我们人一样看整张图，而是先把图片切成一堆不重叠的小方块(patchs)，就像拼图一样。然后，它把每个小方块都转换成一串数字(向量)，再给这些数字加上位置信息(这样AI才知道哪个方块原来在哪个位置)，最后把这些“数字方块”一起丢进“变形金刚”的大脑里去处理²。

ViT的超能力：一眼看穿全局

ViT最厉害的地方，是它从一开始就拥有“全局视野”³。传统的CNN模型像个近视眼，只能先看清一小块局部，然后通过一层层地处理，慢慢地把视野扩大，直到最后才能“看”到整张图的全貌。而ViT不一样，它的“注意力”机制允许任何一个小方块，都能直接和图上所有其他的小方块进行信息交流⁴。这就好比玩“大家来找茬”，ViT能在一瞬间同时比较左上角的云和右下角的船，而不需要从左到右慢慢扫描。这种能力让ViT在理解需要看整体画面的任务时，表现得特别出色³。

致命的弱点：计算量大到“爆炸”

但是，ViT的超能力也带来了巨大的代价：它的计算量和内存消耗，会随着图片变大而急剧增加，而且是“二次方”级别的增长²。这是什么概念呢？假设你把图片的尺寸放大一倍，图片里的小方块数量就变成了原来的4倍，而ViT处理它所需要的计算量，会暴增到惊人的16倍！

这就导致ViT在处理高清大图时，变得非常“烧钱”（耗费计算资源），甚至根本跑不动。偏偏很多重要的视觉任务，比如在图里圈出所有的小汽车（物体检测）、或者把图里的天空、建筑、草地都精确地分割开（图像分割），都离不开高清图⁵。所以，这个“二次方”的计算量问题，成了ViT进一步大展拳脚的最大障碍。

其他的烦恼

除了计算量，ViT还有别的烦恼。因为它不像传统CNN那样有一些“天生的直觉”（比如“相邻的像素点关系更紧密”），所以它学习看图效率比较低，需要看海量的图片数据才能“开窍”，否则很容易学偏²。而且，它那种“一视同仁”的全局关注，有时候会把注意力浪费在无关紧要的背景上，反而抓不住重点¹³。

这些问题揭示了早期ViT设计的一个核心矛盾：能力很强，但代价太高。大家面临一个共同的难题：怎么才能既保留“变形金刚”强大的全局理解能力，又让它变得省钱、高效，能处理各种高清视觉任务呢？为了解决这个问题，研究者们走上了两条不同的道路。一条路是让注意力变得稀疏但固定，代表作是Swin Transformer。另一条路，就是我们今天要深入探讨的，让注意力变得稀疏且动态，其核心技术就是“可变形注意力”。

第二节 “端到端”的检测革命家DETR，为何是个“慢郎中”？

在ViT探索看图分类的同时，“变形金刚”也被引入了更复杂的“物体检测”任务（在图片里框出物体）。一个叫DETR的模型横空出世，它用一种非常简洁优雅的方式，实现了“端到端”的检测。也就是说，它能直接从一张图片，一步到位地输出所有物体的位置和类别，省掉了传统方法里很多复杂的人工设计步骤¹⁵。

问题根源：注意力被“滥用”了

尽管想法很酷，但第一代DETR在实际使用中却暴露了严重问题。最出名的就是它学习得特别慢，训练时间要比主流方法长10倍以上⁸。而且，它找小物件的能力也比较差¹⁵。

究其原因，还是出在那个原始的、不加区分的“全局注意力”上⁸。DETR在工作时，无论是处理图片特征，还是寻找特定物体，都让它的“注意力”扫描整张图片。这就像让一个侦探去找一个嫌疑人，却要求他把城市里的每一个角落、每一块砖头都仔细看一遍。这不仅效率低下，还会被大量无关信息（比如路边的花花草草）干扰，让他晕头转向，很难快速锁定目标。对于小物体来说，它在图片里本来就不起眼，被这么海量的背景信息一冲刷，就更容易被忽略了。

所以，DETR学习慢、找不准小物体，本质上是“全局注意力”这种大而化之的工具，在处理需要精确定位的视觉任务时“水土不服”的表现。

第三节 高效但刻板的Swin Transformer

为了解决ViT和DETR的效率问题，一条重要的改进路线是让注意力变得“稀疏”一些，别什么都看。在这条路上，Swin Transformer是一个里程碑式的模型¹。

窗口化注意力：只看“一亩三分地”

Swin Transformer的核心创新，是把“全局看”改成了“分片看”。它把整张图划分成一个个不重叠的“窗口”，然后让注意力只在每个窗口内部进行计算⁴。这样一来，需要计算的东西就少多了，计算量不再是“二次方”增长，而是和图片大小成正比，处理高清图就变得非常高效。

但只看自己的“一亩三分地”肯定不行，信息不就割裂了吗？为了解决这个问题，Swin Transformer又设计了一个巧妙的“移位窗口”机制。在处理完一轮后，它会把窗口的边界挪动一下，这样，原来在不同窗口边界的像素，下一轮就被分到了同一个新窗口里，大家就有机会互相交流了⁴。通过这样交替使用“窗口内注意”和“移位窗口注意”，Swin Transformer

既保持了高效，又逐步建立了全局的视野。

“一刀切”的局限性

Swin Transformer非常成功，但它也有个根本性的限制：它的注意力模式是**“数据无关”**的，或者说，是“一刀切”的⁷。不管图片里画的是一只猫还是一辆车，它划分窗口的方式都是固定的网格，不会根据图片内容做任何调整。

这种固定的模式虽然高效，但不够灵活。万一一个重要的物体正好被窗口边界给切开了，模型就很难理解这个物体的完整形态¹。Swin Transformer的注意力模式是僵化的，无法根据图像内容动态地调整关注区域。这虽然解决了效率问题，却牺牲了一部分建模的灵活性。

正是这种“一刀切”的特性，为后来的研究留下了改进空间，也催生了另一种截然相反的设计哲学——**“因地制宜”**的动态稀疏注意力，而我们故事的主角“可变形注意力”，正是这一理念的杰出代表。

第二部分：核心创新——让AI学会“指哪看哪”

在ViT的“暴力全局看”和Swin的“固定分片看”之间，其实有很大的优化空间。一个更理想的方案是：既要高效，又要灵活。于是，“可变形注意力”(Deformable Attention)应运而生，它开创了一种“数据相关”的稀疏注意力新模式，让AI学会了根据图片内容，动态地决定该看哪里。

第四节 灵感来源：会“变形”的放大镜

可变形注意力的灵感，来源于传统视觉领域的一项重要发明——可变形卷积(Deformable Convolutional Networks, DCN)¹。

想象一下，普通的AI看图工具就像一个固定形状的放大镜(比如一个3×3的方格)，它总是在固定的九个点位上采集信息。如果遇到一个奇形怪状的物体，比如一只伸懒腰的猫，这个方形的放大镜就很难完美地贴合猫的轮廓。

而DCN就像一个可以变形的放大镜。它不仅看中心点，还会为周围的每个采样点学习一个“偏移量”，告诉它应该往哪个方向挪动一下。这样，放大镜的采样区域就能根据物体的实际形状动态地改变，更好地聚焦在物体本身上¹¹。

直接照搬？行不通！

这个想法太棒了，能不能直接用到“变形金刚”里呢？答案是：不行。因为计算量会再次“爆炸”。如果为每个关注点都去学习一大堆偏移量，计算成本会比原始的全局注意力还要高得多，得不偿失¹¹。

所以，关键在于：如何巧妙地借鉴DCN“学习采样位置”的思想，同时又设计出一种计算上可行的方案？

第五节 可变形注意力模块：技术细节大白话解析

“可变形注意力”模块用一种非常聪明的设计，实现了这个目标。它的核心思想是：对于任何一个关注点，不再让它看所有的东西，而是只让它关注一小部分（比如4个或8个）通过学习找到的最关键的点¹⁵。这就像给侦探配备了一个高科技的“智能探测器”，能自动标出几个最可疑的地点，让他直接去那里搜查就行了。

下面我们一步步拆解这个“智能探测器”是怎么工作的⁶：

1. 确定“基准点”(Reference Points)：

首先，为每个要发出关注的元素（我们称之为“查询”），确定一个初始的“基准点”。这个点就是计算偏移量的起点。比如，在处理一张图片时，每个像素的原始坐标就可以是它的基准点。

2. 生成“偏移指令”(Offset Generation)：

把这个“查询”的信息，输入一个迷你的神经网络。这个小网络的作用，就是根据当前查询的内容，预测出一组“偏移指令”。这些指令告诉我们，从基准点出发，应该往哪些方向、移动多远，去寻找最有价值的信息。

3. 计算“动态采样点”(Deformed Sampling Points)：

把“基准点”和“偏移指令”加在一起，就得到了最终要去“看”的具体位置。因为“偏移指令”是AI自己学出来的，所以这些采样点的位置是动态变化的，能灵活地适应物体的形状和位置。

4. 采集信息(Feature Sampling)：

计算出的采样点坐标可能是小数，但图片是由一个个像素格子组成的。怎么办呢？这里用了一个叫双线性插值的技术。简单说，就是根据这个小数坐标周围四个最近的像素点的信息，来“估算”出这个点上的信息⁶。通过这种方式，AI就能从特征图上任何一个它想看的位置，平滑地提取信息了。

5. 计算注意力(Attention Calculation):

最后一步，还是计算注意力。但和以前不同，现在每个“查询”只需要和刚刚采集到的那少数几个“动态采样点”的信息进行交互。它会判断这几个点中，哪个更重要，就多给它一些“关注度”(权重)，然后把这些点的信息加权汇总起来，就得到了最终的结果。

$\text{DeformAttn}(\text{查询}, \text{基准点}, \text{图片信息}) = \sum \text{权重} \times \text{采样点信息}$

融合不同尺度的信息

可变形注意力的另一个巨大优势，是它能很自然地同时处理来自不同清晰度(尺度)的特征图¹⁵。这就像我们看东西，既会凑近了看细节，也会站远了看整体。可变形注意力可以让它的几个采样点，一部分去高分辨率的图上看细节，另一部分去低分辨率的图上看轮廓，然后把这些信息综合起来，这对识别大小不一的物体特别有帮助。

第六节 可变形注意力 vs. 前辈们: 它到底好在哪？

通过对比，我们能更清楚地看到可变形注意力的创新之处。

vs. 全局注意力 (ViT)

相比ViT的“暴力全局看”，可变形注意力的优势是高效和专注。

- 计算量从二次方降为线性: 全局注意力的计算量是 $N \times N$ (N 是像素点总数)，而可变形注意力只看固定的 K 个点 (K 通常很小，比如4)，计算量是 $N \times K$ ，大大降低了成本⁶。
- 排除干扰: 全局注意力会被大量无关的背景信息干扰。可变形注意力则像一个精准的“过滤器”，主动忽略这些无关部分，把宝贵的计算资源用在刀刃上¹³。

vs. 窗口化注意力 (Swin Transformer)

相比Swin的“固定分片看”，可变形注意力的优势是因地制宜的灵活性。

- 数据相关性: Swin的窗口是固定的网格，一成不变。而可变形注意力的采样点是AI根据图片内容自己学会的。这意味着它的“视野”可以自由变形，去贴合物体的真实形状，不受固定窗口的限制⁷。
- 更强的建模能力: 因为灵活，所以理论上它能学到比固定窗口更好的特征。实验也证明，在差不多的计算成本下，它的性能确实更胜一筹。

vs. 可变形卷积 (DCN)

相比它的灵感来源DCN，可变形注意力的优势在于更通用、更高效。

- 共享偏移量: DCN是为图上每个像素都学习一套独立的偏移量，成本太高。而可变形注意力(尤其是在后来的通用模型DAT中)做了一个关键改进: 让所有的“查询”共享几组学好的偏移量⁶。这就像是发布了几套“公共搜索方案”，大家都可以用，极大地降低了成本，让它能成为一个通用的基础模块。
- 关系建模: DCN本质上还是一个局部操作。而可变形注意力是嵌在“变形金刚”框架里的，天生就继承了强大的关系建模能力。

“智能稀疏”的新范式

从更高层面看，可变形注意力的出现，标志着AI视觉注意力机制的一次重要进化，从“暴力计算”或“手工稀疏”，走向了“智能稀疏”。

1. 全局注意力是“暴力计算”: 不加选择，计算所有东西的关系，简单粗暴但代价高昂。
2. Swin的窗口注意力是“手工稀疏”: 人类开发者预先设计好一种固定的、局部的稀疏模式来省钱。这种模式是静态的，和图片内容无关⁷。
3. 可变形注意力是“智能稀疏”: 它不再依赖固定的模式，而是让AI自己去学习应该把计算资源花在哪里。模型根据内容，动态预测出信息最丰富的区域，并只在这些区域进行重点关注⁶。

这种从“怎么省钱”到“学习在哪花钱”的哲学转变，是可变形注意力成功的根本。它巧妙地结合了稀疏的高效和全局的灵活，实现了能力与成本的最佳平衡。

第三部分：应用、战绩与影响力

可变形注意力不仅是个好点子，它很快就在实际应用中证明了自己，并对后来的AI模型设计产生了深远影响。

第七节 Deformable DETR：让“慢郎中”脱胎换骨

可变形注意力的第一个重要应用，就是拯救那个学习很慢的DETR模型。通过把可变形注意力模块装进DETR的架构里，新的Deformable DETR模型一举解决了前辈的两大难题⁸。

如何改造？

在Deformable DETR里，原来那个“全局扫描”的注意力模块，被换成了新的“多尺度可变形注意力模块”。无论是在分析图片特征，还是在定位物体时，它都只关注从不同清晰度的特征图中采样的一小撮关键点，而不是看整张图。

解决了什么问题？

这个改变立竿见影：

1. 学习速度飙升：因为注意力变得精准聚焦，AI的学习信号更清晰了。它不再需要在大海里捞针，而是可以快速学会关注物体的关键部位（比如中心或边角）。实验证明，Deformable DETR的学习速度比原来快了整整10倍，而且效果还更好¹⁵。
2. 擅长找小物体：新的注意力模块能从更清晰的特征图中采样信息，这些图保留了更多小物体的细节。这让Deformable DETR在找小物体方面表现出色，弥补了前辈的短板

Deformable DETR的成功，不仅让它自己成了一个优秀的物体检测器，更重要的是，它为后来的“变形金刚”检测器指明了方向，其核心思想被许多更先进的模型借鉴和发扬⁸。

第八节 Deformable Attention Transformer (DAT): 一个更通用的“AI之眼”

虽然Deformable DETR里的可变形注意力很成功，但它的设计和物体检测任务绑定得比较紧，不适合直接拿来当一个通用的视觉模型⁶。于是，研究者们对其进行了改进和泛化，提出了

Deformable Attention Transformer (DAT)，一个可以和Swin Transformer等模型正面PK的通用视觉AI⁶。

关键区别在哪里？

DAT和Deformable DETR在实现可变形注意力时，有一个核心的不同。在Deformable DETR里，每个“查询”都会学习一套自己专属的偏移指令。而在DAT里，为了更高效，模型为所有“查询”学习几组共享的偏移指令⁶。也就是说，大家共用同一套“智能搜索方案”。

这个“共享”机制大大降低了计算成本，让可变形注意力可以被高效地用作模型的核心引擎，而不仅仅是一个辅助模块。正是这个关键改进，让DAT从一个特定任务的组件，演变成了一个强大的通用视觉工具⁶。

像搭积木一样分层

和Swin Transformer一样，DAT也采用了分层的“金字塔”结构⁷。它由多个阶段组成，越往深层，图片特征的分辨率越低，但包含的信息越抽象、越高级。这种设计能生成多尺度的特征，可以很方便地用于各种不同的视觉任务。

第九节 公平对决:DAT vs. Swin Transformer

DAT的诞生，就是为了挑战Swin Transformer的王者地位。大量的实验结果表明，凭借其“因地制宜”的动态注意力，DAT在多个主流AI竞赛基准上，用差不多的计算成本，实现了对Swin Transformer的稳定超越。

表1: ImageNet-1K 图像分类性能(比谁认图认得准)

模型	Top-1 准确率 (%)	参数量 (M)	计算量 (G)
Swin-T ⁷	81.3	29	4.5
DAT-T⁷	82.0	28	4.6
Swin-S ⁷	83.0	50	8.7
DAT-S⁷	83.6	50	8.8
Swin-B ⁷	83.3	88	15.4
DAT-B⁷	84.0	89	15.6

数据来源:⁶。

解读:可以看到，在模型大小(参数量)和计算量都差不多的情况下，DAT模型的准确率稳定地比Swin模型高出一截。这说明DAT的动态注意力能更有效地抓住对分类任务有用的关键特征。

表2: COCO 物体检测与实例分割性能(比谁框得准、描得细)

骨干网络	框选准确率 (Box AP)	描边准确率 (Mask AP)
Swin-T ⁷	46.0	41.6
DAT-T⁷	47.1	42.4
Swin-S ⁷	48.5	43.3
DAT-S⁷	49.4	44.0
Swin-B ⁷	49.5	43.9
DAT-B⁷	50.1	44.5

数据来源：⁷。

解读:在更复杂的物体检测和分割任务上, DAT的优势更明显, 性能提升更大。这充分说明, DAT的灵活“视野”能更好地适应各种形状和大小的物体, 从而实现更精准的定位。

表3:ADE20K 语义分割性能(比谁能把图上每个像素都分对类)

骨干网络	平均交并比 mIoU (%)
Swin-T ⁷	47.6
DAT-T⁷	48.6
Swin-S ⁷	49.5
DAT-S⁷	50.4
Swin-B ⁷	49.7
DAT-B⁷	50.9

数据来源:⁶。

解读:在像素级的语义分割任务上, DAT同样表现出色, 得分比Swin Transformer高出1个百分点以上。这表明DAT能更好地理解画面的整体上下文, 同时通过动态采样捕捉到更精细的物体边界。

总而言之, 这些跨越不同任务的“考试成绩”一致证明了, DAT的“智能稀疏”注意力机制, 确实比Swin Transformer的“固定稀疏”注意力机制更强大、更有效。

第十节 思想的传承: DAT++与更广阔的天地

可变形注意力的影响力没有就此停止。它“学习去哪看”的核心思想, 被证明是一个非常通用的工具, 应用范围已经远远超出了计算机视觉。

DAT++的持续进化

在DAT成功的基础上, 原班人马又推出了它的升级版**DAT++**²⁵。虽然具体技术细节公布不多, 但其公布的性能数据再创新高, 在多个榜单上都达到了世界顶尖(SOTA)水平, 进一步巩固了可变形注意力作为顶级视觉AI设计的地位²⁵。

成为一个通用的“智能工具”

可变形注意力最深远的影响, 是它所代表的“学习去哪看”的思想, 已经成为了一个可以被广泛应用的基础工具。它解决了一个普遍存在的问题: 如何在有限的精力下, 从海量信息中高效地提取关键部分。

1. 预测股票走势(时间序列预测): 一个叫**DeformableTST**的新模型, 把可变形注意力用在了时间维度上, 让AI动态地“关注重要的时间点”, 从而能更灵活地分析和预测各种时间序列数据⁴⁰。
2. 分析卫星图片(遥感图像): 遥感图像分辨率超高、背景复杂。研究人员成功地将Deformable-DETR等模型用于遥感图像中的物体检测, 取得了很好的效果⁴²。可变形注意力能有效应对遥感图像中物体大小变化剧烈、背景复杂的挑战。

3. 分析医疗影像(医学影像):在核磁共振(MRI)重建等任务中,图像细节至关重要。研究者们将可变形注意力与其它模型结构结合,在降低计算复杂度的同时,提升了重建图像的质量⁴⁴。
4. 视频追踪(视觉追踪):在一个名为**DeTrack**的模型中,可变形注意力被用来精确地锁定运动的物体,而不需要分析整个视频画面的所有像素,从而提升了追踪的准确性和效率⁴⁵。

这些跨领域的成功应用证明,可变形注意力已经从一个为解决特定问题而设计的模块,演变成了一个通用的、强大的“智能工具”。它所代表的“智能稀疏”范式,为处理各种形式的海量数据提供了一个统一而高效的解决方案。

第四部分:总结与未来

第十一节 总结:一场关于“AI之眼”的进化

本报告讲述了AI视觉注意力机制的一段进化史,核心是“可变形注意力”的诞生和发展。整个故事,其实是为了解决一个核心矛盾:如何让AI看得又广又好,同时又不会累死(计算成本可控)。

故事从ViT开始,它用“全局视野”打破了传统方法的局限,但也陷入了计算量“爆炸”的困境。Swin Transformer用一种“手工”设计的固定窗口方法,大大提高了效率,但牺牲了灵活性,像个高效但刻板的工人。

可变形注意力的出现,是一个关键的转折点。它借鉴了DCN的灵感,但用更聪明的设计,开创了“智能稀疏”的新范式。它不再依赖固定的模式,而是让AI自己学会“该往哪看”,把有限的注意力资源,动态地、数据驱动地分配到最重要的地方。

这种从“手工设计”到“智能学习”的转变,是AI视觉发展的一个里程碑。Deformable DETR和DAT的成功,以及这个思想在其他领域的开花结果,都证明了这种“智能稀疏性”的强大生命力。

第十二节 未来可以做什么?

尽管可变形注意力已经非常成功，但未来还有很多可以探索的方向：

1. 软硬件协同优化：可变形注意力的采样过程是跳跃式的，这和我们电脑GPU芯片为连续读写设计的优化策略不太匹配，可能导致实际运行速度没有理论上那么快²⁶。未来可以设计专门的硬件或软件算法来加速这种动态的访问模式³¹。
2. 优化“偏移指令”的生成：目前用来生成“偏移指令”的小网络还比较简单。未来可以探索更聪明、更高效的网络结构，让AI能做出更精准的判断。
3. 与其它先进技术结合：可以把可变形注意力与其它AI领域的最新技术（比如自监督学习、混合架构等）结合起来，强强联手，创造出更强大的模型。
4. 在新兴领域的应用：在当前火热的多模态大模型和生成式AI领域，可变形注意力大有可为。比如，在“文生图”或“图生文”任务中，它可以帮助模型根据文字描述，精准地在图像中聚焦于相关区域。在视频理解、3D点云处理等领域，它的潜力同样巨大。

总而言之，可变形注意力不仅是过去几年AI视觉领域最重要的技术突破之一，它的核心思想也为未来人工智能的设计提供了宝贵的启示。对“智能稀疏性”的持续探索，将继续引领我们走向一个更高效、更强大、更通用的智能新时代。

Works cited

1. Object Detection Based on Swin Deformable Transformer-BiPAFPN-YOLOX - PMC, accessed July 27, 2025, <https://pmc.ncbi.nlm.nih.gov/articles/PMC10019960/>
2. From Pixels to Predictions: Understanding Vision Transformers | by Salman Ibne Eunus | The AI Educator | Medium, accessed July 27, 2025, <https://medium.com/the-ai-educator/from-pixels-to-predictions-understanding-vision-transformers-43eb13fa6056>
3. Vision Transformers - The Future of Computer Vision! | ResearchGate, accessed July 27, 2025, https://www.researchgate.net/post/Vision_Transformers-The_Future_of_Computer_Vision
4. Vision Transformer vs. Swin Transformer: A Conceptual Comparison - HIYA CHATTERJEE, accessed July 27, 2025, https://hiya31.medium.com/vision-transformer-vs-swin-transformer-a-conceptual-comparison-6502d9b949f2?source=rss-----artificial_intelligence-5
5. ViTAR: Vision Transformer with Any Resolution - arXiv, accessed July 27, 2025, <https://arxiv.org/html/2403.18361v2>
6. Vision Transformer With Deformable Attention - CVF Open Access, accessed July 27, 2025, https://openaccess.thecvf.com/content/CVPR2022/papers/Xia_Vision_Transformer_With_Deformable_Attention_CVPR_2022_paper.pdf
7. [2201.00520] Vision Transformer with Deformable Attention, accessed July 27, 2025, <https://arxiv.org/html/2201.00520>

8. Paper Review: Deformable Transformers for End-to-End Object Detection., accessed July 27, 2025, <https://cenk-bircanoglu.medium.com/paper-review-deformable-transformers-for-end-to-end-object-detection-ed0a452f775f>
9. High Resolution Images and Efficient Transformers | by Ahmed Taha - Medium, accessed July 27, 2025, <https://ahmdtaha.medium.com/high-resolution-images-and-efficient-transformers-92db6f8803f7>
10. Win-Win: Training High-Resolution Vision Transformers from Two Windows - OpenReview, accessed July 27, 2025, <https://openreview.net/forum?id=N23A4ybMJr>
11. Introducing Deformable Attention Transformer | by Joe El Khoury - GenAI Engineer | Medium, accessed July 27, 2025, <https://medium.com/@jelkhoury880/introducing-deformable-attention-transformer-ddb8b5363c5c>
12. [D] Why is ViT more commonly used than SWIN? : r/MachineLearning - Reddit, accessed July 27, 2025, https://www.reddit.com/r/MachineLearning/comments/1b3bhbd/d_why_is_vit_more_commonly_used_than_swin/
13. Vision Transformer with Deformable Attention (2201.00520v3) - Emergent Mind, accessed July 27, 2025, <https://www.emergentmind.com/articles/2201.00520>
14. Vision Transformer with Deformable Attention - X-MOL, accessed July 27, 2025, <https://www.x-mol.com/paper/1478415819391258624?adv>
15. Deformable DETR: Deformable Transformers for End-to-End Object Detection | Request PDF - ResearchGate, accessed July 27, 2025, https://www.researchgate.net/publication/344551949_Deformable_DETR_Deformable_Transformers_for_End-to-End_Object_Detection
16. Deformable DETR: Deformable Transformers for End-to-End Object Detection. - GitHub, accessed July 27, 2025, <https://github.com/fundamentalvision/Deformable-DETR>
17. Diving into the difference between DAT(Deformable Attention Transformer) paper's approach and... - Medium, accessed July 27, 2025, <https://medium.com/@hanbrianlee/diving-into-the-difference-between-dat-deformable-attention-transformer-papers-approach-and-44bdf4ba5fa2>
18. Deformable DETR Explained - Papers With Code, accessed July 27, 2025, <https://paperswithcode.com/method/deformable-detr>
19. Deformable DETR: Deformable Transformers for End-to-End Object Detection | OpenReview, accessed July 27, 2025, <https://openreview.net/forum?id=gZ9hCDWe6ke>
20. [R] Deformable DETR: Deformable Transformers for End-to-End Object Detection - Reddit, accessed July 27, 2025, https://www.reddit.com/r/MachineLearning/comments/j7u4t4/r_deformable_detr_deformable_transformers_for/
21. A SWIN-based vision transformer for high-fidelity and high-speed imaging experiments at light sources - Frontiers, accessed July 27, 2025,

- <https://www.frontiersin.org/journals/high-performance-computing/articles/10.3389/fhpcp.2025.1537080/full>
22. Swin Transformer in Depth: Architecture and PyTorch Implementation | by Övül Arslan, accessed July 27, 2025, <https://medium.com/@ovularslan/swin-transformer-in-depth-architecture-and-pytorch-implementation-a11e44d65aef>
 23. Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows - CVF Open Access, accessed July 27, 2025, https://openaccess.thecvf.com/content/ICCV2021/papers/Liu_Swin_Transformer_Hierarchical_Vision_Transformer_Using_Shifted_Windows_ICCV_2021_paper.pdf
 24. arXiv:2201.00520v3 [cs.CV] 24 May 2022 - SciSpace, accessed July 27, 2025, <https://scispace.com/pdf/vision-transformer-with-deformable-attention-3eo9321v.pdf>
 25. arxiv.org, accessed July 27, 2025, <https://arxiv.org/abs/2309.01430>
 26. Deformable Attention, accessed July 27, 2025, <https://ericwiener.github.io/ai-notes/AI-Notes/Attention/Deformable-Attention>
 27. (PDF) Vision Transformer with Deformable Attention - ResearchGate, accessed July 27, 2025, https://www.researchgate.net/publication/357552925_Vision_Transformer_with_Deformable_Attention
 28. [2201.00520] Vision Transformer with Deformable Attention - arXiv, accessed July 27, 2025, <https://arxiv.org/abs/2201.00520>
 29. lucidrains/deformable-attention: Implementation of Deformable Attention in Pytorch from the paper "Vision Transformer with Deformable Attention" - GitHub, accessed July 27, 2025, <https://github.com/lucidrains/deformable-attention>
 30. Vision Transformer With Deformable Attention, accessed July 27, 2025, https://openaccess.thecvf.com/content/CVPR2022/html/Xia_Vision_Transformer_With_Deformable_Attention_CVPR_2022_paper.html
 31. LeapLabTHU/DAT: Repository of Vision Transformer with ... - GitHub, accessed July 27, 2025, <https://github.com/LeapLabTHU/DAT>
 32. Xia Vision Transformer With Deformable Attention CVPR 2022 Paper | PDF - Scribd, accessed July 27, 2025, <https://www.scribd.com/document/759780177/Xia-Vision-Transformer-With-Deformable-Attention-CVPR-2022-paper>
 33. Swin Transformer — MMClassification 0.25.0 documentation - Read the Docs, accessed July 27, 2025, https://mmclassification.readthedocs.io/en/dev-1.x/papers/swin_transformer.html
 34. Vision Transformer with Deformable Attention | alphaXiv, accessed July 27, 2025, <https://www.alphaxiv.org/overview/2201.00520v3>
 35. Vision Transformer with Super Token Sampling - arXiv, accessed July 27, 2025, <https://arxiv.org/html/2211.11167v2>
 36. DAT++: Spatially Dynamic Vision Transformer With Deformable Attention | PDF - Scribd, accessed July 27, 2025, <https://www.scribd.com/document/674791533/DAT-Spatially-Dynamic-Vision-Transformer-with-Deformable-Attention>

37. DAT++: Spatially Dynamic Vision Transformer with Deformable Attention - X-MOL, accessed July 27, 2025, <https://www.x-mol.com/paper/1699544211659706368?adv>
38. LeapLabTHU/DAT-Segmentation: Repository of Vision Transformer with Deformable Attention (CVPR2022) and DAT++ - GitHub, accessed July 27, 2025, <https://github.com/LeapLabTHU/DAT-Segmentation>
39. Dat AI Project Repository Download and Installation Guide - Albase, accessed July 27, 2025, <https://www.aibase.com/repos/project/dat>
40. This is an official implementation of "DeformableTST: Transformer for Time Series Forecasting without Over-reliance on Patching" (NeurIPS 2024) - GitHub, accessed July 27, 2025, <https://github.com/luodhhh/DeformableTST>
41. DeformableTST: Transformer for Time Series Forecasting without Over-reliance on Patching - NIPS, accessed July 27, 2025, https://proceedings.neurips.cc/paper_files/paper/2024/file/a0b1082fc7823c4c68abcab4fa850e9c-Paper-Conference.pdf
42. Deformable Attention Mechanisms Applied to Object Detection, case of Remote Sensing Paper accepted at the 29th International Conference on Knowledge-Based and Intelligent Information and Engineering Systems (KES 2025) - arXiv, accessed July 27, 2025, <https://arxiv.org/html/2505.24489v1>
43. Deformable Attention Mechanisms Applied to Object Detection, case of Remote Sensing, accessed July 27, 2025, https://www.researchgate.net/publication/392315037_Deformable_Attention_Mechanisms_Applied_to_Object_Detection_case_of_Remote_Sensing
44. Swin Deformable Attention U-Net Transformer (SDAUT) for Explainable Fast MRI - arXiv, accessed July 27, 2025, <https://arxiv.org/abs/2207.02390>
45. Object Tracking Network Based on Deformable Attention Mechanism - BMVC 2022, accessed July 27, 2025, <https://bmvc2022.mpi-inf.mpg.de/0469.pdf>