

深入解析Step3的大语言模型优化创新:多矩阵分解注意力与注意力-FFN解耦

I. 执行摘要

Step3引入了两项关键创新,旨在解决大型语言模型(LLM)推理中的核心瓶颈:多矩阵分解注意力(MFA)及其变体MFA-Key-Reuse(MFA-KR),以及注意力-FFN解耦技术。这些技术的核心目标是优化LLM推理效率,尤其是在处理键值(KV)缓存内存占用和GPU资源利用率不足的问题上。

MFA和MFA-KR通过重新思考注意力头的扩展方式,采用低秩矩阵分解,显著减少了KV缓存的内存使用(MFA-KR相比标准多头注意力MHA可减少高达93.7%¹),同时保持甚至提升了模型性能。这代表了一种从根本上优化KV缓存生成方式的架构创新。

注意力-FFN解耦作为一种更广泛的解耦趋势的一部分,旨在通过分离计算密集型(预填充、注意力)和内存密集型(解码、FFN)阶段来优化LLM服务系统的资源利用率。这种分离能够实现更高效的资源分配和更高的吞吐量。

这些创新的综合影响使得Step3在提升LLM部署的成本效益和可扩展性方面取得了显著进展,特别是在长上下文和多租户场景中。

KV缓存是LLM推理的主要瓶颈,尤其是在上下文长度增加的情况下⁴。这个瓶颈不仅是内存容量问题,更是内存带宽和推理延迟的关键限制,因为KV缓存的需求随序列长度线性增长,并且在自回归解码过程中需要持续访问。这一根本性挑战推动了研究界朝着多样化但最终趋同的方向发展:

1. 直接压缩:量化⁸和聚类¹²等技术旨在减小KV缓存的原始大小。
2. 架构重新设计:MFA/MFA-KR¹和LaCache的结构化模式⁹等创新改变了KV对的生成或存储方式,使其本身更高效。
3. 系统级管理:Medha¹¹、MIRAGE²¹、PagedAttention⁶以及注意力解耦机制²³等方法侧重于KV缓存资源在推理管道中的智能处理、调度和分配。

这种趋同表明,整合从基础模型架构到复杂系统级管理的多层优化方法,对于实现真正可

扩展和高效的长上下文LLM部署至关重要。Step3对MFA/MFA-KR(架构创新)和注意力-FFN解耦(系统级优化)的双重关注,与这一新兴趋势完美契合,预示着相比仅解决问题单一方面的方案, Step3提供了一个更全面、更强大的解决方案。

II. LLM推理挑战与优化格局介绍

LLM自回归解码中KV缓存的关键作用及其内存/计算瓶颈

大型语言模型(LLM),特别是基于Transformer解码器架构的模型,以自回归方式运行,一次生成一个token⁴。这种顺序生成过程需要访问所有先前处理过的token的上下文。为了避免在每个解码步骤中重复计算所有先前token的注意力键和值,这些中间状态被存储在键值(KV)缓存中⁴。这种缓存机制是自回归解码效率的基础。

然而, KV缓存的内存需求随上下文长度(token数量)和批处理大小线性增长⁴。这种线性增长导致巨大的内存消耗,成为一个显著的瓶颈,特别是对于旨在处理极长上下文(例如,高达100万甚至1000万token)的现代LLM¹¹。尽管KV缓存避免了重复计算,但生成每个新token都需要访问整个缓存历史。这使得内存访问和带宽成为推理延迟和整体吞吐量的关键瓶颈⁷。解码阶段通常被认为是内存带宽受限的,这意味着推理时间的大部分用于数据传输而非实际计算⁷。

在生产环境中部署LLM涉及多阶段的复杂交互:初始的“预填充”阶段(处理输入提示)、迭代的“解码”阶段(自回归生成输出token)、“非活跃”阶段(在保留缓存的同时等待用户输入),以及“后续预填充”阶段(用于多轮对话)⁴。管理这些动态转换和在各阶段维护昂贵的KV缓存,对高效的LLM部署和资源管理构成了巨大挑战⁴。其中,“非活跃阶段”中KV缓存驻留在内存中,在高吞吐量系统中尤其耗费资源⁴。

LLM推理优化领域的概览,为Step3的创新奠定基础

研究界正通过多管齐下的方法积极应对这些挑战:

- 模型压缩技术:量化²⁵和剪枝²²等方法旨在减小整体模型大小和内存占用,使LLM更

易于部署在资源受限的硬件上。

- **KV缓存特定优化**：此类别包括直接针对KV缓存的方法，例如KV值的量化⁸、相似KV对的聚类¹²、不重要tokens的驱逐策略⁶，以及注意力机制本身的架构重新设计（例如，MFA/MFA-KR）¹。
- **系统级优化**：这些优化涉及推理服务系统层面的高级调度、并行策略和复杂的内存管理⁶。例子包括自适应预填充分块、流水线并行和动态内存重用。

所有这些优化工作的总体目标是显著提高吞吐量、降低延迟，并支持更大的批处理大小和更长的上下文长度，这对于将LLM部署到生产规模和边缘设备至关重要⁸。

KV缓存内存被认为是LLM推理中的主要或最显著瓶颈⁵。这不仅仅是存储模型所需的总容量问题，更关键的是在自回归解码阶段高效访问不断增长的KV缓存所需的内存带宽。尽管自注意力机制本身具有二次方的计算成本¹⁰，但引入KV缓存正是为了避免重复计算，从而有效地将瓶颈从原始计算转移到内存访问和数据传输。解码步骤是“内存带宽受限”的说法⁷进一步证实了这一点。这表明，仅仅增加计算能力（例如，更快的GPU）并不能完全解决LLM推理瓶颈，除非软件和架构方面有补充创新，能够大幅减少需要传输的数据量，或优化数据访问和管理方式。对内存占用减少策略（如量化、聚类 and 高效数据结构）的强烈强调⁷是一个关键主题，表明它们的重要性超越了单纯的原始计算能力。这意味着未来的硬件设计也必须优先考虑内存带宽和为LLM工作负载量身定制的高效缓存层次结构。

预填充阶段计算密集型和解码阶段内存密集型之间的持续区分是一个反复出现的主题⁴。传统的解耦方法通常将这些阶段拆分到不同的机器上，以防止性能干扰，但这往往导致显著的资源利用不足²³。这突出了一种根本性的矛盾：孤立地优化一个阶段可能会在另一个阶段造成效率低下或资源闲置。这种矛盾直接推动了对更复杂“解耦”策略的需求，这些策略超越了简单的分离。相反，这些策略旨在动态地“重新整合”或“重新编排”任务，以平衡整个推理管道的资源利用率。Step3的“注意力-FFN解耦”³⁰和Adrenaline的“注意力解耦和卸载”²³正是应对这一挑战的直接回应。它们旨在动态重新分配计算和内存任务，以保持GPU持续繁忙，而不是依赖导致资源利用不足的静态分区。这标志着LLM服务系统中从静态资源分配向动态、细粒度、工作负载感知资源共享的关键转变。

III. Step3的核心创新：详细技术分析

A. 多矩阵分解注意力(MFA)和MFA-Key-Reuse(MFA-KR)

传统MHA和现有变体(MQA、GQA、MLA)在严格KV缓存预算下的局限性

键值(KV)缓存的内存占用是LLM解码阶段的主要瓶颈,其大小与批处理大小和序列长度呈线性关系¹。这种巨大的内存占用和流量严重限制了部署。为了减少KV缓存使用,已经提出了多查询注意力(MQA)、分组查询注意力(GQA)和多头潜在注意力(MLA)等现有注意力机制⁶。MQA和GQA通过在多个注意力头之间共享键和值投影来实现这一目标⁶。MLA则对键和值投影应用低秩压缩¹。

然而,这些方法在严格的KV缓存预算下通常难以保持强大的性能¹。这种性能下降归因于对键和值投影的额外限制,这无意中限制了注意力模块的建模能力¹。研究指出,注意力头的数量和维度对于维持建模能力至关重要,而现有方法对此探索不足¹。此外,一些先进方法如MLA,在支持广泛采用的位置嵌入(如旋转位置嵌入RoPE)方面引入了额外的架构复杂性,并且可能对初始化方法敏感¹。

MFA方法论:在查询-键(QK)电路中进行低秩矩阵分解,以实现注意力头的有效扩展

多矩阵分解注意力(MFA)是一种新型注意力架构,旨在开发高效且有效的注意力模块,以最小化参数和KV缓存大小¹。其目标是将模型的容量尽可能地推向完全参数化双线性注意力(FPBA)的理论上限¹。该方法论建立在对注意力机制建模能力的详细分析之上,从而形成了MFA的三个关键设计策略:

1. 增加头的数量和维度:这种设计选择旨在最小化传播过程中的通道共享,并为每个注意力头提供更大的表达自由度,这对于保持模型容量至关重要¹。
2. 对 Wn 应用激进的低秩矩阵分解:这一策略提高了参数效率,使模型能够有效扩展而不会产生过多的参数开销¹。
3. 利用单键值头技术:这种方法专门用于保持最小的KV缓存使用量¹。

具体而言,MFA在查询-键(QK)电路中采用低秩矩阵分解¹。这使得注意力头的数量和维度能够以参数高效的方式进行扩展,而不会导致过多的KV缓存使用。每个token的键和值以一种将每个token的KV缓存减少到

$2C$ (其中 C 是与头维度相关的常数)的方式进行计算¹。

MFA-KR方法论: 重用键缓存作为值以进一步减少内存

MFA-Key-Reuse (MFA-KR) 是MFA架构的扩展, 旨在进一步优化KV缓存的使用¹。其核心机制涉及通过重新参数化的值投影来重用键缓存作为值¹。这种重新参数化具体定义为

$S_v = S_k + \alpha \odot N S_k$, 其中 α 被初始化为零向量以确保训练稳定性¹。这种巧妙的修改使得KV缓存使用量在MFA的基础上额外减少50%, 而对模型性能的影响可以忽略不计²。

主要发现: 与MHA和MLA相比的性能(准确性、KV缓存减少)

广泛的实验表明, MFA的性能优于MLA, 并且与标准多头注意力(MHA)的性能相当, 在某些情况下甚至超越MHA¹。例如, 在一个经过1万亿token训练的7B参数模型中, MFA的平均基准准确率达到49.9%, 而MHA为49.0%¹。

MFA显著减少了KV缓存的使用。与MLA相比, 它实现了高达56%的减少; 与MHA相比, 在一个7B参数模型中, 它实现了惊人的87.5%的减少(从每token 196.6KB降至24.6KB)¹。MFA-KR进一步推动了这些节省, 将KV缓存使用量减少到每token仅12.3KB, 这仅是MHA存储需求的6.25%。这使得MFA-KR非常适合KV缓存限制极其严格的场景, 尽管会带来轻微的性能权衡¹。

在可扩展性方面, MFA与MHA的损失扩展行为相匹配, 证实了其强大的建模能力和有效扩展的能力。MFA-KR也表现出类似的扩展趋势, 仅有轻微的性能差距。至关重要的是, MFA和MFA-KR的相对KV缓存节省随着模型尺寸的增大而增加, 这表明它们对更大规模部署的效率益处日益显著¹。MFA的一个显著优势在于其与当前LLM训练和推理生态系统的自然契合。与一些现有方法(例如MLA)不同, MFA在支持广泛采用的位置嵌入(如RoPE)方面不引入额外的架构复杂性, 从而确保了实际应用¹。

创新: MHA变体的统一视角(GMHA、FPBA)指导MFA设计

这项工作的一个核心创新是提供了现有MHA变体的统一理论视角¹。研究引入了广义多头注意力(GMHA)的概念, 并确定完全参数化双线性注意力(FPBA)是此框架内注意力容量的理论上限¹。这个框架将MHA及其变体定位为FPBA的低秩分解, 为分析和设计提供了统

一的理论参考点¹。这种深刻的理论理解直接指导了MFA的设计原则。MFA的设计允许在增加注意力头数量的同时,以最小的参数开销保持KV缓存大小不变,无论头的数量如何¹。这是在实现容量和效率方面的一个重大进步。

许多KV缓存优化方法(例如,量化、驱逐)侧重于对已生成的KV缓存元素进行事后压缩或移除,而MFA/MFA-KR则代表了一种更根本的架构重新设计¹。这是一个关键的区别。MFA/MFA-KR并非压缩现有KV缓存,而是从一开始就设计为生成一个天然较小的KV缓存。这种方法本质上避免了与事后方法相关的一些权衡,例如由于激进量化可能导致的准确性下降或由于驱逐造成的不可逆信息损失。这表明LLM设计可能发生范式转变:未来的高效LLM可能从头开始构建,采用MFA等内存高效的注意力机制,而不是仅仅依赖于在标准MHA模型训练后应用的优化。这种“设计即效率”的方法可以带来更优越的准确性-效率权衡的模型,并可能简化部署流程,因为对复杂、分层的事后优化的需求可能会减少。

研究明确指出,先前的KV缓存减少方法(MQA、GQA、MLA)在严格的内存预算下通常无法保持强大的性能,因为它们限制了注意力模块的容量¹。MFA的创新在于它能够在减少KV缓存大小的同时,增加头的数量和维度。这种看似反直觉的成就得益于“QK电路中的低秩矩阵分解”¹,它实现了参数高效的扩展。这表明核心问题不仅仅是减少内存占用,而是在不牺牲模型表达能力和捕获复杂关系能力的情况下智能地进行。GMHA和FPBA的统一理论视角¹为MFA设计如何成功保持容量提供了严谨的基础。这突出表明,真正有效的LLM优化超越了暴力削减;它需要深入理解注意力机制的底层数学结构及其与模型容量的关系。在约束条件下,理论上以保持或增强建模能力为基础的解决方案,更有可能具有鲁棒性,并实现更优越的性能-效率帕累托前沿。MFA的方法为实现紧凑的内存占用和高性能提供了一条可行的路径,解决了LLM部署中的一个关键矛盾。

B. 注意力-FFN解耦

传统预填充-解码解耦中的资源利用不足问题以及MoE模型中FFN的内存密集性

在大型语言模型(LLM)服务系统中,每个请求的执行通常涉及两个连续阶段:计算密集型“预填充”阶段(处理输入提示)和内存密集型“解码”阶段(自回归生成输出token)²³。为了防止这些不同阶段之间的性能干扰,当前的LLM服务系统通常采用“预填充-解码(PD)解耦”,即将这两个阶段分离并在不同的机器或GPU实例上运行²³。

然而,这种传统方法通常导致显著的资源利用不足。具体而言,计算密集型的预填充实例内

存利用率较低，而内存密集型（主要由于KV缓存）的解码实例计算利用率较低²³。这种静态分区造成了资源闲置。对于专家混合（MoE）模型，问题更加严重。其稀疏激活的架构使得前馈网络（FFN）在推理过程中从计算密集型转变为内存密集型，导致GPU利用率大幅降低和运营成本增加²⁶。GPU内存限制和响应延迟约束对批处理大小施加了上限，阻碍了FFN充分利用MoE模型中可用的GPU计算能力³²。

方法论：解耦注意力与FFN模块以实现独立扩展和异构部署

Step3的“注意力-FFN解耦”³⁰被提出作为一项新颖的优化技术，据称在处理长上下文时比现有模型（如DeepSeek和Qwen）更具成本效益。尽管现有资料中没有详细说明Step3的具体实现，但Adrenaline和MegaScale-Infer等相关前沿研究为理解这一新兴范式提供了强有力的背景。

- **Adrenaline**（注意力解耦）：这种机制旨在通过将解码阶段中部分注意力计算从内存密集型解码阶段解耦并卸载到运行计算密集型预填充阶段的GPU上，从而提高资源利用率²³。该策略旨在平衡负载，提高预填充实例中高带宽内存（HBM）的容量和带宽利用率，并增加有效解码批处理大小以提高解码实例中的计算利用率²³。Adrenaline整合了低延迟解码同步、资源高效预填充共置和负载感知卸载调度等技术，以管理这种动态资源共享的复杂性²⁴。
- **MegaScale-Infer**（MoE特定解耦）：该系统通过在每个模型层内解耦注意力模块和FFN模块，并将其分配给独立的GPU以实现独立扩展和定制并行策略，从而进一步推进了解耦²⁶。在此架构中，注意力模块通常使用数据并行进行复制，而FFN模块则使用专家并行进行扩展³²。这种细粒度分离还支持异构部署，允许系统利用GPU的不同能力（例如，注意力模块的经济高效内存容量和带宽，以及FFN的经济高效计算能力）以降低运营成本³²。
- 关键技术（来自相关工作，为Step3的方法提供背景）：
 - 乒乓流水线并行：为了解决解耦造成的空闲期和通信开销，MegaScale-Infer引入了乒乓流水线并行策略。该技术将请求批处理划分为微批处理，并在注意力模块和FFN模块之间高效地穿梭，确保两个模块持续繁忙并有效隐藏通信开销²⁶。
 - 高性能M2N通信库：在解耦的MoE架构中，注意力模块和FFN模块的独立扩展将通信模式从“全对全”转换为“多对多”（M2N）。MegaScale-Infer开发了一个专门的M2N通信库，消除了不必要的GPU到CPU数据复制、组初始化开销和GPU同步，从而最大限度地减少了数据传输开销并提高了通信稳定性²⁶。
 - 部署计划搜索算法：MegaScale-Infer利用一种算法来搜索最优部署计划。该算法考虑了注意力模块和专家节点的张量并行大小、注意力节点的数量、微批处理的数量以及全局批处理大小等各种因素，目标是在满足延迟约束的同时最大化单位成本吞吐量³²。

主要发现:GPU利用率、吞吐量和成本效益的提升

尽管Step3的注意力-FFN解耦的具体详细发现未在现有资料中广泛提供, 仅提及其“比DeepSeek和Qwen模型更具成本效益, 尤其是在长上下文方面”³¹, 但相关解耦系统所展示的性能提升高度预示了其潜在收益。

- **Adrenaline**: 在预填充实例中实现了2.28倍的内存容量提升和2.07倍的内存带宽利用率提升。它还使解码实例的计算利用率提高了高达1.67倍, 并且整体推理吞吐量比现有系统高出1.68倍²³。
- **MegaScale-Infer**: 展示了显著的改进, 在同构集群上实现了高达1.90倍的每GPU吞吐量提升。对于Scaled-MoE模型, 与vLLM和TensorRT-LLM相比, 它将每GPU解码吞吐量分别提高了7.11倍和1.90倍³²。在异构集群上, MegaScale-Infer实现了1.7倍的每美元吞吐量提升, 与H20上的vLLM和TensorRT-LLM相比, 单位成本吞吐量分别提高了3.24倍和1.86倍³²。其专门的M2N通信库也比NCCL实现了4.2倍的吞吐量提升和68.2%的延迟降低, 适用于常用数据大小³²。

LLM服务系统中最初的解耦方法是分离预填充和解码阶段²³。虽然这避免了干扰, 但也导致了显著的资源利用不足。新的趋势, 以MegaScale-Infer为代表, 并由Step3的“注意力-FFN解耦”³⁰所暗示, 是在模型层内进行解耦, 特别是分离注意力模块和FFN模块²⁶。这代表了一种更细粒度、更复杂的方法。这种演变的原因在于, 注意力模块和FFN模块具有不同的计算和内存特性, 尤其是在MoE模型中, FFN由于稀疏激活可能变得内存密集²⁶。这种演变表明LLM系统设计日益复杂, 超越了简单的阶段分离, 转向对模型计算图进行更细粒度、工作负载感知的分解。这允许高度专业化的并行策略和异构硬件的有效利用, 通过精确匹配不同模型组件的特定计算和内存需求与最优硬件和调度策略, 从而突破了效率的极限。这也表明未来的LLM服务系统可能会高度自适应和动态, 能够编排复杂的计算流。

虽然解耦有望在资源利用方面带来显著优势, 但它也必然引入了分离模块或阶段之间的通信开销挑战²³。MegaScale-Infer通过开发“高性能M2N通信库”²⁶明确解决了这一问题, 这被认为是其整体成功的关键。这突出表明, 如果模块间通信没有得到精心优化, 解耦的理论优势很容易被抵消。像“乒乓流水线并行”²⁶这样的技术正是为了通过重叠计算和通信来隐藏这种通信延迟而设计的直接响应。这强调了LLM的系统级优化不仅仅是孤立地优化计算或内存访问, 而是越来越关注分布式组件之间高效的数据移动和同步。随着LLM变得越来越大, 其服务架构越来越分布式和解耦, 底层的网络基础设施和GPU间通信结构变得与GPU的计算单元或内存带宽一样关键。通信库和调度算法的创新, 以最小化同步开销, 对于这些先进、分布式LLM架构的实际和经济高效部署至关重要。

IV. 比较分析: Step3在现有技术中的地位

A. KV缓存优化技术

量化

核心原理: 量化是一种广泛采用的技术, 它将LLM中数值的精度(包括模型权重、激活和KV缓存)从高精度格式(例如FP32、FP16)降低到低精度格式(例如INT8、INT4甚至INT2)³³。这种压缩直接减少了内存使用, 并能显著加快推理速度。

优势: 量化为LLM部署带来了多项优势。它允许更大的模型适应内存有限的GPU, 大幅减少每token的KV缓存大小(从而通过在相同GPU内存中容纳更多并行请求来提高吞吐量和并发性), 加速推理(特别是在边缘设备或批处理过程中), 并降低整体计算需求, 从而减少运营成本和能耗²⁸。

挑战: 尽管有诸多益处, 量化不可避免地会引入模型准确性方面的权衡, 尤其是在降低到极低位宽(例如, 低于4位)时⁸。一个主要困难源于KV缓存分布中“异常值”(极高值)的存在, 这些异常值难以用低位定点格式精确表示²²。此外, 现有方法通常忽略了KV缓存量化的层级敏感性, 在线细粒度决策开销高, 并且可能缺乏对不同LLM和硬件约束的灵活性⁸。

具体方法:

- **KIVI**: 一种无需微调的即插即用2位KV缓存量化算法⁸。KIVI的设计基于键缓存和值缓存对量化表现出不同敏感度的观察。它对键缓存进行逐通道量化, 对值缓存进行逐token量化³⁵。该方法使Llama-2-7B和Falcon等模型的峰值内存使用量减少2.4倍至2.6倍, 同时准确性损失极小, 从而使真实LLM推理工作负载的批处理大小增加4倍至8倍, 吞吐量提高2.05倍至3.47倍³⁵。
- **IntactKV**: 该方法解决了先前被忽视的一类异常值, 即“枢轴token”(例如, 输入开头的和常见标点符号), 它们对注意力分数产生不成比例的影响⁸。IntactKV提出从全精度模型无损地生成这些枢轴token的KV缓存, 有效地使它们“完整”³⁶。这种简单、即插即用的方法与大多数现有量化解决方案正交, 并且可以在不增加额外推理开销的情况

下与它们结合使用³⁶。它还在理论上降低了量化误差的上限³⁶。

- **KVQuant**: 一种用于高效KV缓存量化的综合方法, 旨在实现准确的低精度量化, 从而实现极长上下文长度的推理(单个A100-80GB GPU上可达100万token, 8-GPU系统上可达1000万token)¹⁴。KVQuant整合了多项创新, 包括逐通道键量化(在RoPE之前应用)、具有敏感度加权数据类型的非均匀KV缓存量化、逐向量稠密-稀疏量化以及用于归一化量化质心的Q-Norm策略¹⁴。它在Wikitext-2和C4等基准测试中实现了低于0.1的困惑度下降, 采用3位量化¹⁵。
- **QAQ**(质量自适应量化): 该方案基于理论证明, 提出对键缓存和值缓存采用不同的量化策略, 因为它们对量化表现出不同的敏感度⁸。QAQ整合了专用的异常值处理和改进的注意力感知方法, 以实现KV缓存大小高达10倍的压缩比, 同时对模型性能影响可忽略不计¹⁷。
- **MiKV**: 一种细粒度方法, 动态识别关键KV缓存条目并即时更新其精度以提高准确性⁸。
- **ZipCache**: 一种准确高效的KV缓存量化方法, 通过通道可分离的逐token量化方案构建了强大的基线, 与细粒度组式量化相比, 显著减少了量化参数的内存开销¹⁸。为了提高压缩比, ZipCache提出使用归一化注意力分数作为识别显著token的有效指标, 并根据其显著性自适应分配量化位宽¹⁸。它在LLaMA3-8B模型上, 输入长度为4096时, 展示了显著的效率提升, 包括预填充阶段延迟减少37.3%, 解码阶段延迟减少56.9%, 以及GPU内存使用量减少19.8%¹⁸。

KIVI、QAQ、KVQuant和IntactKV等多种KV缓存量化方法都一致地认识到键缓存和值缓存对量化具有不同的敏感度, 因此需要不同的优化策略⁸。具体而言, 键缓存通常被认为是更敏感的, 并且容易包含对性能至关重要的“异常值”(极端值)³⁶。这导致了专门的技术, 例如键的逐通道量化(KIVI、KVQuant)和值的逐token量化(KIVI), 或者保持“枢轴token”(通常包含异常值)以更高精度完整保留的策略(IntactKV)。这种更深层次的理解意味着挑战不仅仅是“如何量化”, 而是“量化KV缓存的哪些特定部分以及如何对每个部分应用最合适的量化方案”。这种对KV缓存特征的细粒度理解表明, 简单、一刀切的量化方法对于LLM来说是次优的。未来的进展可能涉及更细粒度、自适应和上下文感知的量化方案, 这些方案利用对KV缓存不同组件如何影响整体模型性能的细致理解。这种固有的复杂性也意味着持续需要强大的校准方法, 以及可能需要硬件感知的量化技术, 以最大限度地提高效率, 同时避免在实际部署中造成显著的准确性下降。

尽管KV缓存量化方法提供了显著的内存节省(例如, QAQ高达10倍压缩¹⁷, KIVI高达2.6倍³⁵), 但Step3的MFA/MFA-KR等架构修改实现了更大幅度的KV缓存减少(MFA-KR相比MHA高达93.7%¹)。这种量化差异表明, 根本性的架构改变可以比单独的事后量化带来更深刻、更内在的内存节省。然而, 多项资料也明确提到了量化方法与其他优化的兼容性; 例如, MIRAGE与“量化方法”和“KV缓存压缩框架”兼容²¹, IntactKV“简单且易于与现有量化解决方案结合”³⁶。这暗示了架构重新设计和量化之间的协同关系。MFA/MFA-KR通过从根本上改变注意力的计算和缓存方式, 提供了固有的内存效率基线。然后, 可以在这些经过架构

优化的模型之上应用量化，以实现更大的压缩和效率，从而进一步突破界限。针对极长上下文或边缘设备部署的最终解决方案，很可能涉及多层优化堆栈，从高效的注意力机制开始，并在此基础上叠加复杂的自适应量化技术。这种集成方法对于在资源受限环境中充分发挥LLM的潜力至关重要。

聚类、驱逐和压缩

- **Chelsea**(在线KV缓存聚类)：Chelsea被提出作为一种简单而有效的在线KV缓存聚类框架，旨在提高LLM在长上下文场景中的推理效率¹²。其核心创新是分块软匹配算法。该算法将序列分成块，在每个块内采用交替分区策略，并根据相似性识别聚类，然后将每个聚类内的KV缓存合并为一个单一的质心¹²。Chelsea实现了KV缓存内存使用量高达80%的减少，同时保持了可比的模型性能。此外，它以最小的计算开销将推理的解码阶段加速高达3.19倍，并将端到端延迟减少高达2.72倍¹²。它被描述为一种轻量级、即插即用的解决方案¹²。
- **LaCache**(梯形KV缓存和迭代压缩)：LaCache是一种无需训练的KV缓存优化范式，用于高效准确的LLM生成推理⁹。LaCache集成了两项关键创新：(1) 一种梯形KV缓存模式，它不仅按顺序(每层从左到右)存储KV对，而且跨层(从浅层到深层)存储，在固定存储预算下提供扩展的范围以捕获长距离依赖关系⁹。这种配置通过在早期层保留早期token的KV状态，并逐步将焦点转移到后续层中的后期token，形成阶梯状结构，从而增强了长距离能力⁹。LaCache还与迭代压缩机制相结合，以支持无限长序列的连续生成而不会出现内存溢出(OOM)问题⁹。它定期对先前压缩的KV状态应用基于梯形的压缩模式，为新token腾出空间。它更激进地压缩旧token，同时对新token应用较少压缩，使模型能够优先处理最新信息，同时高效管理传入token的内存⁹。LaCache的有效性已通过实验和消融研究得到验证，其结果表明它增强了长距离能力并支持连续生成。由于其与FlashAttention的兼容性，它在可实现的准确性-吞吐量权衡方面优于H2O等基于重要性的方法⁹。
- **Medha**：Medha是一个端到端系统，用于高效的长上下文LLM推理，通过细粒度时间共享解决现有挑战¹¹。Medha引入了三项关键创新：(1) 自适应预填充分块机制，通过抢占有助于缓解头端阻塞(HOL blocking)；(2) 两种新的并行策略：序列流水线并行(SPP)通过流水线预填充块来减少首个token时间(TTFT)，以及KV缓存并行(KVP)来降低每token时间¹¹。Medha实现了超过1000万token的精确推理扩展，在混合长度工作负载下保持高吞吐量和低延迟¹¹。与现有系统相比，Medha减少了服务器碎片化，将中位延迟降低了高达30倍，吞吐量提高了5倍以上¹¹。其关键的实现机制是预填充分块，它将长上下文请求拆分为更小的块，允许预填充和解码一起批处理¹¹。这种方法允许更细粒度的控制，提高了对不同上下文长度下预填充和解码延迟服务水平目标(SLO)的遵守¹¹。
- **MIRAGE**：MIRAGE是一个动态重映射引擎，旨在通过重映射模型参数来优化多租户

LLM服务环境中的KV缓存利用率²¹。其核心创新在于动态参数重映射策略。当KV缓存需求超出可用GPU内存时，MIRAGE内的重映射控制器会回收一部分最初分配给模型参数的GPU内存，以支持更大的KV缓存²¹。与KV缓存交换不同，参数重映射是CPU到GPU内存的非阻塞、单向数据传输，显著减少了同步开销²¹。MIRAGE根据运行时需求以层粒度调整KV缓存大小，并做出自适应运行时决策²¹。它在集成到vLLM中时表现出显著的性能提升，与基线vLLM相比，尾部token间时间(TBT)延迟减少44.8%-82.5%，尾部首个token时间(TTFT)延迟减少20.7%-99.3%，吞吐量增加6.6%-86.7%²¹。

- **ShadowKV**: ShadowKV是一种高吞吐量长上下文LLM推理系统，它通过存储低秩键缓存并卸载值缓存来减少内存占用，以支持更大的批处理大小和更长的序列⁵。它利用键向量在应用位置编码前具有低秩特性，这导致了一种新颖的卸载算法⁵。ShadowKV在各种模型和任务上实现了高达6倍的批处理大小和高达3倍的吞吐量提升⁵。
- **SpindleKV**: SpindleKV是一种新型KV缓存减少方法，旨在平衡浅层和深层³⁸。对于深层，它采用基于注意力权重的驱逐方法；对于浅层，它应用基于码本的替换方法，该方法通过相似性和合并策略学习³⁸。SpindleKV还解决了其他基于注意力的驱逐方法面临的分组查询注意力(GQA)困境³⁸。实验表明，SpindleKV在保持相似甚至更好的模型性能的同时，获得了比基线方法更好的KV缓存减少效果³⁸。

与Step3(MFA/MFA-KR)的比较：Step3的MFA/MFA-KR方法与上述许多技术在KV缓存优化方面有所不同。虽然Chelsea、LaCache、Medha、MIRAGE、ShadowKV和SpindleKV主要侧重于压缩、管理或动态调整已生成的KV缓存，但MFA/MFA-KR通过架构重新设计，从根本上改变了注意力机制，使其从一开始就生成一个更小的KV缓存。MFA-KR高达93.7%的KV缓存减少率¹极具竞争力，甚至优于Chelsea的80%减少率¹²。这种“设计即效率”的方法避免了事后压缩可能带来的信息损失，并可能与这些系统级优化方法协同工作，以实现更深层次的效率提升。

B. 系统级优化和部署考量

预填充-解码解耦(通用)

预填充-解码解耦是一种将LLM推理的两个主要阶段——计算密集型预填充阶段和内存密集型解码阶段——分离的策略²³。最初，这种分离通常通过将这两个阶段部署在不同的机器或GPU实例上来实现，以避免它们之间的性能干扰²³。然而，这种粗粒度的分离常常导致资源利用率低下，例如预填充实例的内存利用率低，而解码实例的计算利用率低²³。为了解决这个问题，注意力-FFN解耦等更细粒度的方法应运而生，旨在在模型层内分离注意力模

块和前馈网络(FFN)模块²⁶。这种演变反映了LLM服务系统设计中从静态资源分配向更动态、细粒度、工作负载感知资源共享的转变。

并行策略(通用)

除了架构解耦,各种并行策略也在提升LLM推理效率方面发挥着关键作用。例如,Medha系统引入了序列流水线并行(SPP)和KV缓存并行(KVP)¹¹。SPP通过流水线处理预填充块来减少首个token时间(TTFT),从而提高效率。KVP则旨在降低每token时间,通过并行处理KV缓存数据来加速解码阶段¹¹。这些并行策略与解耦方法相辅相成,共同优化了计算和内存资源的利用,尤其是在处理长上下文和混合长度工作负载时¹¹。

内存管理(通用)

KV缓存的内存管理是LLM部署中的另一个关键领域。PagedAttention是一个由vLLM推理框架推广的复杂缓存管理层⁶。它通过将注意力键值缓存分割成块来优化内存使用,从而实现在序列和请求之间的内存共享⁶。PagedAttention的机制类似于操作系统管理虚拟内存和物理内存的方式,它在需要时分配非连续的物理GPU内存块,并通过动态映射表将虚拟缓存视图映射到这些物理块⁶。这种方法提高了内存利用率,并支持更大的批处理大小和更长的上下文长度。

边缘设备部署

将LLM部署到智能手机、笔记本电脑和机器人等资源受限的边缘设备上,面临着计算限制、内存约束和硬件异构性等重大挑战²⁸。LLM固有的计算密集性和内存需求常常超出边缘硬件的能力,导致无法加载整个模型²²。低位量化是解决这些内存优化挑战的关键技术,它通过压缩模型和减少内存需求来实现更高效的操作²⁸。最近在低位量化方面的进展使得混合精度矩阵乘法(mpGEMM)对于LLM变得可行²⁸。具体技术包括:

- **mpGEMM**: 一种允许不同精度级别数据(如int8*int1、int8*int2或FP16*int4)相乘的深度学习技术,旨在平衡速度、内存效率和计算准确性²⁸。
- **Ladder数据类型编译器**: 将数据存储与计算分离,支持更广泛的自定义数据类型,并将低位数据转换为硬件最有效的格式²⁸。它在NVIDIA和AMD GPU上表现出色,对非原

生支持的自定义数据类型可实现高达14.6倍的加速²⁸。

- **T-MAC mpGEMM库**：一种基于查找表(LUT)的方法，无需反量化或乘法即可实现mpGEMM，用位级表查找取代传统乘法运算²⁸。它在边缘设备上展示了显著的效率和速度优势，例如在Raspberry Pi 5上，3B BitNet-b1.58模型能以每秒11个token的速度生成²⁸。
- **LUT Tensor Core硬件架构**：一种针对低位LLM推理的软硬件协同设计，通过优化技术(如软件DFG转换、操作融合和表对称化)解决了传统LUT方法的预计算开销²⁸。它在低位LLM上实现了6.93倍的推理速度提升，同时仅使用传统Tensor Core 38.3%的面积²⁸。

这些技术共同推动了LLM在边缘设备上的可行性，支持模型扩展和具身AI系统(如机器人)的发展²⁸。

多租户服务

在多租户环境中，多个LLM实例或用户请求共享同一套硬件资源。MIRAGE系统在这一领域提供了显著的优化²¹。它通过参数重映射来优化KV缓存利用率，将部分分配给模型参数的GPU内存动态地重新用于支持更大的KV缓存²¹。这种方法避免了KV缓存交换带来的高CPU内存流量和同步开销²¹。MIRAGE特别有利于多租户环境，因为它能够高效且主动地重用分配给非活跃模型的内存，将其参数存储重新用作活跃模型的KV缓存²¹。这在vLLM中实现了显著的性能提升，包括尾部TBT延迟减少44.8%-82.5%，尾部TTFT延迟减少20.7%-99.3%，以及吞吐量增加6.6%-86.7%²¹。

Step3的定位

Step3的注意力-FFN解耦与上述系统级优化方法高度相关。它通过在模型层内更细粒度地分离计算和内存密集型模块，进一步提升了资源利用率和吞吐量。这种方法与Medha的并行策略和PagedAttention的内存管理理念相契合，共同构建了一个更高效的LLM服务生态系统。特别是，Step3的解耦方法在MoE模型中具有显著优势，通过独立扩展和异构部署来优化FFN的利用率。其声称在长上下文场景中比现有模型更具成本效益³¹，表明它在实际部署中能够提供有竞争力的性能和经济效益。

V. 结论

Step3在LLM优化领域的贡献，特别是其多矩阵分解注意力(MFA)和注意力-FFN解耦技术，代表了解决当前LLM推理瓶颈的关键进展。MFA及其变体MFA-KR通过在架构层面重新设计注意力机制，实现了KV缓存的显著减少，同时保持甚至提升了模型性能。这种方法从根本上优化了KV缓存的生成，而非仅仅事后压缩，展现了“设计即效率”的理念，预示着未来LLM将更注重从模型构建之初就融入内存效率。

注意力-FFN解耦则体现了系统级优化的最新趋势，即从粗粒度的预填充-解码阶段分离转向更细粒度的模块级解耦。这种方法能够更有效地平衡GPU资源利用率，特别是在处理MoE模型中FFN的内存密集性问题时。相关研究(如Adrenaline和MegaScale-Infer)的成果表明，这种解耦策略能够显著提升吞吐量、降低延迟并提高成本效益，通过精细的并行策略和优化的通信机制来隐藏分布式系统中的开销。

总体而言，Step3的创新与当前LLM优化领域的核心发展方向高度契合：致力于克服“内存墙”的限制，并实现计算和内存资源的动态、高效利用。这些技术不仅为长上下文LLM的部署提供了更可扩展和成本效益的解决方案，也为未来LLM架构和系统设计的融合指明了方向。未来的研究和开发将可能进一步探索这些多层优化策略的协同作用，以期在性能、效率和部署可行性之间取得更优的平衡。

Works cited

1. Multi-matrix Factorization Attention, accessed July 26, 2025, <https://arxiv.org/pdf/2412.19255>
2. Multi-matrix Factorization Attention - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2412.19255v2>
3. Multi-matrix Factorization Attention - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2412.19255v1>
4. Transformers At The Edge: Efficient LLM Deployment - Semiconductor Engineering, accessed July 26, 2025, <https://semiengineering.com/transformers-at-the-edge-efficient-llm-deployment/>
5. ShadowKV: KV Cache in Shadows for High-Throughput Long-Context LLM Inference, accessed July 26, 2025, <https://openreview.net/forum?id=oa7MYAO6h6>
6. Techniques for KV Cache Optimization in Large Language Models - omrimallis, accessed July 26, 2025, <https://www.omrimallis.com/posts/techniques-for-kv-cache-optimization/>
7. LLM Inference Series: 4. KV caching, a deeper look | by Pierre Lienhart | Medium, accessed July 26, 2025, <https://medium.com/@plienhar/llm-inference-series-4-kv-caching-a-deeper-look-4ba9a77746c8>

8. ICML Poster KVtuner: Sensitivity-Aware Layer-Wise Mixed ..., accessed July 26, 2025, <https://icml.cc/virtual/2025/poster/43487>
9. LaCache: Ladder-Shaped KV Caching for Efficient Long-Context Modeling of Large Language Models - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2507.14204>
10. KV-Latent: Dimensional-level KV Cache Reduction with Frequency-aware Rotary Positional Embedding - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2507.11273v1>
11. Medha: Efficient LLM Inference on Multi-Million Context Lengths Without Approximation, accessed July 26, 2025, <https://arxiv.org/html/2409.17264v4>
12. Efficient Long-Context LLM Inference via KV Cache Clustering - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2506.11418v1>
13. KIVI: Plug-and-play 2bit KV Cache Quantization with Streaming Asymmetric Quantization - ResearchGate, accessed July 26, 2025, https://www.researchgate.net/profile/Zirui-Liu-29/publication/376831635_KIVI_Plug-and-play_2bit_KV_Cache_Quantization_with_Streaming_Asymmetric_Quantization/links/658b5d282468df72d3db3280/KIVI-Plug-and-play-2bit-KV-Cache-Quantization-with-Streaming-Asymmetric-Quantization.pdf
14. [NeurIPS 2024] KVQuant: Towards 10 Million Context Length LLM Inference with KV Cache Quantization - GitHub, accessed July 26, 2025, <https://github.com/SqueezeAILab/KVQuant>
15. KVQuant: A Leap in LLM Context Length - GoatStack AI, accessed July 26, 2025, <https://goatstack.ai/topics/kvquant-a-leap-in-llm-context-length-fcdcyo>
16. KVQuant: Towards 10 Million Context Length LLM Inference with KV Cache Quantization, accessed July 26, 2025, <https://slice.eecs.berkeley.edu/papers/kvquant-towards-10-million-context-length-llm-inference-with-kv-cache-quantization/>
17. (PDF) QAQ: Quality Adaptive Quantization for LLM KV Cache - ResearchGate, accessed July 26, 2025, https://www.researchgate.net/publication/384108540_QAQ_Quality_Adaptive_Quantization_for_LLM_KV_Cache
18. ZipCache: Accurate and Efficient KV Cache Quantization with Salient Token Identification - NIPS, accessed July 26, 2025, https://proceedings.neurips.cc/paper_files/paper/2024/file/7e57131fdeb815764434b65162c88895-Paper-Conference.pdf
19. (PDF) Efficient Long-Context LLM Inference via KV Cache Clustering - ResearchGate, accessed July 26, 2025, https://www.researchgate.net/publication/392717024_Efficient_Long-Context_LLM_Inference_via_KV_Cache_Clustering
20. Multi-matrix Factorization Attention - OpenReview, accessed July 26, 2025, <https://openreview.net/pdf?id=DDGYklzeIN>
21. MIRAGE: KV Cache Optimization through Parameter ... - arXiv, accessed July 26, 2025, <https://arxiv.org/abs/2507.11507>
22. (PDF) A Review on Edge Large Language Models: Design ..., accessed July 26, 2025,

- https://www.researchgate.net/publication/384974008_A_Review_on_Edge_Large_Language_Models_Design_Execution_and_Applications
23. Injecting Adrenaline into LLM Serving: Boosting Resource Utilization and Throughput via Attention Disaggregation - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2503.20552v1>
 24. Injecting Adrenaline into LLM Serving: Boosting Resource ... - arXiv, accessed July 26, 2025, <https://arxiv.org/pdf/2503.20552>
 25. LLM quantization | LLM Inference Handbook - BentoML, accessed July 26, 2025, <https://bentoml.com/llm/getting-started/llm-quantization>
 26. [2504.02263] MegaScale-Infer: Serving Mixture-of-Experts at Scale with Disaggregated Expert Parallelism - arXiv, accessed July 26, 2025, <https://arxiv.org/abs/2504.02263>
 27. HydraInfer: Hybrid Disaggregated Scheduling for Multimodal Large Language Model Serving - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2505.12658v1>
 28. Advances to low-bit quantization enable LLMs on edge devices ..., accessed July 26, 2025, <https://www.microsoft.com/en-us/research/blog/advances-to-low-bit-quantization-enable-llms-on-edge-devices/>
 29. AI Model Deployment Explained: Tools & Best Practices, accessed July 26, 2025, <https://orq.ai/blog/ai-model-deployment>
 30. [Feature]: Attention-FFN disaggregation · Issue #21644 · vllm-project ..., accessed July 26, 2025, <https://github.com/vllm-project/vllm/issues/21644>
 31. stepfun is about to release a 321B-A38B model : r/singularity - Reddit, accessed July 26, 2025, https://www.reddit.com/r/singularity/comments/1m8wumc/stepfun_is_about_to_release_a_321ba38b_model/
 32. MegaScale-Infer: Serving Mixture-of-Experts at Scale with ..., accessed July 26, 2025, <https://arxiv.org/pdf/2504.02263>
 33. LLM Quantization | GPTQ | QAT | AWQ | GGUF | GGML | PTQ | by Siddharth vij | Medium, accessed July 26, 2025, <https://medium.com/@siddharth.vij10/llm-quantization-gptq-qat-awq-gguf-ggml-ptq-2e172cd1b3b5>
 34. What is LLM Quantization ? - YouTube, accessed July 26, 2025, <https://m.youtube.com/watch?v=vFLNdOUvD90&pp=0gcJCU8JAYcqIYzv>
 35. KIVI: Tuning-Free 2-Bit KV Cache Quantization - Emergent Mind, accessed July 26, 2025, <https://www.emergentmind.com/articles/2402.02750>
 36. IntactKV: Improving Large Language Model Quantization by Keeping Pivot Tokens Intact - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2403.01241v1>
 37. IntactKV: Improving Large Language Model Quantization by Keeping Pivot Tokens Intact | Read Paper on Bytez, accessed July 26, 2025, <https://bytez.com/docs/arxiv/2403.01241/paper>
 38. [2507.06517] SpindleKV: A Novel KV Cache Reduction Method Balancing Both Shallow and Deep Layers - arXiv, accessed July 26, 2025, <https://arxiv.org/abs/2507.06517>