

对 DeepSeek-V3 的全面分析:技术颠覆与前沿人工智能的新经济学

引言:DeepSeek 范式转移

DeepSeek-V3 的发布不仅仅是一次技术迭代,更是一个分水岭时刻。它对长期主导人工智能(AI)领域的“算力为王”哲学构成了直接挑战。本报告的核心论点是, DeepSeek-V3 的主要贡献在于证明了一条通过算法和工程效率实现前沿模型性能的可行路径,从而改变了 AI 开发的经济和战略格局。

这一事件在硅谷和整个科技界引发了冲击波,促使投资者重新评估 AI 产业¹。DeepSeek-AI 作为一家相对年轻且规模不大的中国公司,凭借其有限的资源,取得了与资金雄厚的美国科技巨头(如 OpenAI 和 Anthropic)相媲美的成果,这一现象被描述为对 AI 行业的“颠覆”²。

本报告将系统性地剖析这一成就。首先,我们将对 DeepSeek-V3 的核心技术创新进行解构;其次,分析其训练效率和基准性能;再次,深入研究其背后的公司实体及其独特的战略;最后,评估其对全球 AI 生态系统的战略影响。

第一节:DeepSeek-V3 技术报告行政简报

本节旨在为时间有限的利益相关者提供一份关于核心论文⁴的简明技术摘要,为后续的深度分析奠定事实基础。

论文概览

- 标题、作者与机构:论文标题为《DeepSeek-V3 Technical Report》,作者署名为 DeepSeek-AI 团队,而非罗列个人研究者,这体现了公司层面的统一努力⁴。

- 摘要总结: 论文摘要清晰地阐述了模型的核心参数: 一个拥有 6710 亿 (671B) 总参数的混合专家 (MoE) 模型, 每个 token 激活 370 亿 (37B) 参数。报告强调, 模型通过采用在 DeepSeek-V2 中已验证的 Multi-head Latent Attention (MLA) 和 DeepSeekMoE 架构, 实现了卓越的性能和极具成本效益的训练。其完整训练仅需 278.8 万 H800 GPU 小时。此外, 论文声称其首创了无辅助损失的负载均衡策略, 并引入了多 token 预测 (MTP) 训练目标, 以进一步提升模型能力⁴。
- 声称的主要贡献: 论文明确提出了四项主要贡献: 1) 一个高效且性能强大的 MoE 架构; 2) 一种新颖的无辅助损失负载均衡策略; 3) 验证了多 token 预测 (MTP) 训练目标的有效性; 4) 在超大规模模型上首次验证了 FP8 混合精度训练的可行性和有效性⁴。

表 1: DeepSeek-V3 模型规格一览

下表提供了模型的关键技术参考, 以便读者在深入分析前迅速掌握其规模和核心架构选择。

| 特性 | 规格 | 来源 |
|---------------|--|--------------|
| 总参数量 | 685B (主模型 671B + MTP 模块 14B) | ⁴ |
| 每 token 激活参数量 | 37B | ⁴ |
| 基础架构 | 混合专家 (MoE) Transformer | ⁴ |
| 注意力机制 | 多头潜在注意力 (Multi-head Latent Attention, MLA) | ⁴ |
| MoE 配置 | 257 个专家 (1 个共享, 256 个路由), 每 token 激活 8 个 | ⁴ |
| 上下文长度 | 128K (通过 YaRN 从 4K 扩展) | ⁴ |
| 训练数据量 | 14.8 万亿 tokens | ⁴ |
| 总训练计算量 | 278.8 万 H800 GPU 小时 | ⁴ |

第二节:架构三位一体:解构 DeepSeek-V3 的核心创新

本节将从“是什么”深入到“如何实现”和“为何重要”，对支撑 DeepSeek-V3 性能与效率的三大核心技术进行学术层面的深度剖析。

2.1 重塑注意力机制:多头潜在注意力(MLA)的理论与实践

KV 缓存问题

在深入探讨 MLA 之前，必须首先理解自回归语言模型在推理过程中面临的一个根本性瓶颈：键值缓存(KV Cache)。在生成每个新 token 时，模型需要关注(attend to)之前的所有 token。为了避免重复计算，先前 token 的键(Key, K)和值(Value, V)状态被缓存起来。然而，随着上下文长度和模型规模的增加，这个 KV 缓存会变得异常庞大，成为主要的内存瓶颈，从而限制了模型的扩展能力⁸。

MLA 的技术分解

MLA 正是为解决这一关键问题而设计的。其核心思想是利用低秩分解(low-rank factorization)技术，将高维的 K 和 V 状态压缩到一个低维的潜在向量中。这种压缩显著减小了 KV 缓存的尺寸⁴。具体而言，MLA 并非直接为每个查询头(Query head)生成独立的 K 和 V，而是先生成一个共享的、压缩后的潜在向量，再通过一个可学习的上投影矩阵(up-projection matrix)为每个查询头“解压”出独特的 K 和 V。此外，为了兼容旋转位置编码(Rotary Position Embedding, RoPE)，MLA 设计了一种“解耦 RoPE”机制，将位置信息承载于一个独立的子头中，从而在压缩格式下保留了位置编码的有效性⁸。

对比分析:MLA vs. GQA/MQA

为了凸显 MLA 的创新性，有必要将其与另外两种主流的 KV 缓存优化技术——多查询注意力 (Multi-Query Attention, MQA) 和分组查询注意力 (Grouped-Query Attention, GQA) 进行比较。MQA 和 GQA 通过让多个查询头共享同一组 K 和 V 头来减少缓存大小，但这是一种性能上的妥协，因为共享机制会降低模型的表达能力⁹。

MLA 的路径则截然不同。它通过学习表达能力更强的上、下投影矩阵，用少量的额外计算换取了通信开销的大幅降低和更优的模型性能¹¹。理论研究甚至证明，任何 GQA 结构都可以被等效地表示为 MLA，但反之则不然。这意味着在相同的 KV 缓存开销下，MLA 拥有更大的模型表达潜力¹²。

性能影响

MLA 带来的效率提升是巨大的。分析表明，相较于等效的 GQA 实现，MLA 在 KV 缓存计算上所需的内存和浮点运算 (FLOPs) 减少了约 12 倍；而与标准的多头注意力 (MHA) 相比，更是减少了约 60 倍¹³。这使得模型能够在不耗尽内存的情况下处理更长的上下文序列。

表 2: 注意力机制对比分析 (MHA vs. GQA vs. MLA)

| 特性 | 多头注意力 (MHA) | 分组查询注意力 (GQA) | 多头潜在注意力 (MLA) |
|-----------|-------------|----------------------|----------------|
| KV 缓存大小 | 高 | 中 | 低 |
| 模型表达能力 | 高 | 中等(有损) | 高(通过学习投影保持) |
| KV 缓存生成开销 | 高 | 中 | 低 |
| 核心创新 | 独立 K/V 头 | 分组共享 K/V 头 | 学习低秩投影 |
| 代表模型 | Llama 7B | Llama 2 70B, Mixtral | DeepSeek-V2/V3 |

2.2 完善专家混合:无辅助损失的 MoE 及其意义

MoE 负载均衡的历史背景

混合专家(MoE)模型通过在每个 Transformer 层中设置多个“专家”(通常是前馈网络),并由一个“路由器”(router)为每个 token 动态选择一小部分专家进行计算,从而在不显著增加计算成本的情况下大幅扩展模型参数量。然而,MoE 训练中的一个核心挑战是负载均衡:如果路由器倾向于选择少数几个“受欢迎”的专家,会导致这些专家被过度训练,而其他专家则被“饿死”,最终导致模型性能下降和参数冗余¹⁴。传统的解决方案是引入一个辅助损失函数(auxiliary loss),对不均衡的路由决策进行惩罚¹⁴。

辅助损失的问题

尽管辅助损失在一定程度上解决了负载不均衡问题,但它也带来了新的麻烦。这个额外的损失项会产生“干扰梯度”(interference gradients),这些梯度与模型主要的语言建模任务目标可能存在冲突,从而损害模型的最终性能¹⁷。在训练过程中,研究者需要在模型性能和负载均衡之间进行艰难的权衡。

DeepSeek 的创新:无损失均衡

DeepSeek-V3 首创了一种无辅助损失的负载均衡策略,巧妙地规避了上述问题⁴。该方法的核心是在路由器的 logits 上引入一个动态的、非可训练的“偏置项”(bias)。这个偏置项根据每个专家的近期负载情况进行动态调整:被忽视的专家偏置会增加,被过度选择的专家偏置会减少。

最关键的一点是,这个偏置项仅用于影响 Top-K 路由决策(即选择哪些专家),而不参与最终专家输出的加权求和。这意味着它不会向后传播任何梯度,从而彻底消除了对主任务的

干扰⁴。

性能影响

论文中的消融实验表明，与传统的基于辅助损失的方法相比，这种无损失均衡策略在保持出色负载均衡的同时，能够在大多数基准测试上实现更好的模型性能⁴。这证明了移除干扰梯度能够让模型在训练中达到更高的性能上限。

2.3 超越下一个词元：多词元预测 (MTP) 的双重效用

MTP 作为预训练目标

传统的语言模型预训练目标是预测下一个 token。DeepSeek-V3 采用了多 token 预测 (Multi-Token Prediction, MTP) 目标，即在每个位置上，模型被训练去预测未来的一系列 (例如 k 个) token⁴。这迫使模型学习更长程的依赖关系和更复杂的语言结构。论文的消融研究证实，采用 MTP 目标能够持续提升模型在多数评估基准上的表现⁴。

MTP 用于推理加速

MTP 模块的第二个功能是在推理时实现投机解码 (speculative decoding)，从而加速生成过程。其工作原理是：利用 MTP 模块一次性生成一个候选 token 序列，然后由基础模型并行地对这个序列进行验证。如果验证通过，就可以一次性接受多个 token，而不是逐个生成。论文报告称，第二个 token 的接受率在 85% 到 90% 之间，这使得解码速度提升了 1.8 倍⁴。

灵活性

这种设计的一个重要优点是其模块化。在推理时，如果不需要投机解码加速，MTP 模块可以被完全丢弃，而不会影响主模型的任何功能⁴。

第二节 洞察与启示

DeepSeek-V3 的架构三位一体 (MLA、无损失 MoE、MTP) 并非孤立的技术技巧，而是一套相互关联、系统级的效率优化方案。MLA 通过压缩 KV 缓存，为 MoE 模型在长上下文场景下的应用扫清了内存障碍，使得更大规模的专家网络成为可能。接着，无损失的 MoE 均衡机制消除了传统 MoE 训练中的性能惩罚，让模型能够充分利用 MoE 带来的参数优势。最后，MTP 不仅通过更复杂的预训练任务提升了基础模型的能力，还利用同一模块实现了推理加速。这个组合形成了一个良性循环：更优的架构允许更高效地训练出更强大的模型，而这个模型在推理时又能运行得更快。这是一次算法与系统协同设计的典范。这些被开源的技术为竞争者提供了一条清晰的路径来弥合效率差距，特别是 MLA 的成功，可能会引发行业在下一代模型中从 GQA 转向 MLA 的浪潮¹²。

第三节：效率的工程学：基础设施与训练方法论

本节将分析支撑 DeepSeek-V3 惊人训练效率的软硬件协同设计，从架构理论转向工程实践。

3.1 HAI-LLM 框架与 FP8 训练的前沿探索

DeepSeek-V3 的高效训练离不开其自研的 HAI-LLM 训练框架。该框架采用了一种复杂的并行策略组合：16 路流水线并行 (PP)、64 路专家并行 (EP) 和 ZeRO-1 数据并行 (DP)⁴。为了克服大规模 MoE 训练中常见的通信瓶颈，团队开发了创新的

DualPipe 流水线算法和定制化的 all-to-all 通信核。这些技术的核心目标是最大化计算与通信的重叠，从而有效“隐藏”节点间的通信延迟，这对于 MoE 训练效率至关重要⁴。

一项重大的工程成就是成功地在如此大规模的模型上应用了 FP8 混合精度训练。这是业界首次在百亿亿级别参数模型上验证 FP8 的可行性。报告详细描述了为确保数值稳定性而采取的策略，例如对特定关键操作保持更高精度、采用细粒度的量化缩放以及使用更高精度的累加器。这表明 DeepSeek-AI 在低精度训练方面拥有成熟且领先的技术积累⁴。

3.2 解构 560 万美元的声明: AI 训练的新经济学

DeepSeek-V3 最引人注目的声明之一是其极低的训练成本。报告声称，其完整训练仅需 278.8 万 H800 GPU 小时，总成本估算约为 560 万美元²。这一数字与业界普遍估计的 GPT-4 超过 1 亿美元的训练成本，以及 Llama 3.1 405B 高出 10 倍的计算成本形成了鲜明对比²。

然而，对这一数字的解读必须谨慎。社区的讨论和论文本身的说明都指出，这个成本仅指最终一次成功的训练运行的计算成本。它并未包含以下几个方面的巨大投入²⁰：

- 硬件采购成本: 据报道，DeepSeek 的母公司在美国实施芯片出口限制前，就已购入多达 10,000 块英伟达 A100 GPU³。
- 研发成本: 在最终成功运行之前，进行了大量的架构探索、算法实验和失败的训练尝试，这些成本并未计算在内²⁰。
- 人力资本成本: 维持一支庞大且高水平的研究团队的薪资开销²¹。

因此，560 万美元这个数字更应被理解为在完成所有前期研发后，生产一个 DeepSeek-V3 模型的边际成本。尽管如此，这仍然是革命性的。它意味着 DeepSeek-AI 已经开发出了一套可复制的、低边际成本的训练“配方”。这使得模型的后续迭代、微调和更新，都能够以远低于竞争对手的成本进行。

表 3: 前沿模型训练成本与效率对比

| 模型 | 总参数量 | 报告的训练计算量 | 报告/估算的成本 |
|----------------|------|-----------------------|-------------------|
| DeepSeek-V3 | 671B | 2.788M H800 GPU-hours | ~\$5.6M |
| Llama 3.1 405B | 405B | ~28M H100 | ~\$70-100M (est.) |

| | | | |
|-------|----------------|------------------|----------------|
| | | GPU-hours (est.) | |
| GPT-4 | N/A (est. >1T) | N/A | >\$100M (est.) |

注:Llama 3.1 和 GPT-4 的数据为基于公开信息和行业分析的估算值。

第三节 洞察与启示

DeepSeek 的真正创新不在于其项目的总成本神奇地低，而在于创造了一套可复制的、低边际成本的训练配方。其路径可以概括为：首先，通过母公司的雄厚资本进行长期的、大规模的硬件和人才投资³。然后，利用这些资源进行密集的、高风险的基础研发，最终产出了一系列突破性的架构和工程创新。这些创新的成果，就是那套极其高效的“训练配方”，使得每一次成功训练的边际成本降至惊人的低水平。这一模式将 AI 领域的竞争从纯粹的资本竞赛（谁能负担得起最昂贵的单次训练）转向了创新竞赛（谁能开发出最高效的训练方法）。它表明，一个资金充裕但组织敏捷的机构，完全可以通过卓越的工程技术，在竞争中超越规模更大、可能更官僚的现有巨头。

第四节：实证检验：多维度性能分析

本节旨在批判性地评估 DeepSeek-V3 的性能，综合官方基准测试结果与社区的定性反馈，以判断模型是否名副其实。

4.1 技术领域的SOTA表现：代码与数学推理

DeepSeek-V3 在技术类基准测试中表现尤为突出。在 Codeforces、SWE-bench、HumanEval、LiveCodeBench、MATH-500 和 AIME 2024 等多个高难度代码和数学推理任务上，它的得分不仅超越了所有其他开源模型，甚至在某些项目上与顶尖的闭源模型（如 GPT-4o 和 Claude 3.5 Sonnet）相当或更优⁴。值得注意的是，其中一些 benchmarks（如 LiveCodeBench 和 MATH-500）的卓越性能，还得益于从其专门的推理模型

DeepSeek-R1 中进行的知识蒸馏，这是一个重要的技术细节⁴。

4.2 通用能力: 语言、推理与长上下文理解

在通用语言和推理能力方面, DeepSeek-V3 同样表现强劲。在 MMLU-Pro、GPQA-Diamond 等综合性基准测试中, 它稳居开源模型前列, 并与闭源领导者展开激烈竞争。在衡量长文本理解能力的 LongBench v2 基准上, 其 128K 的上下文窗口也使其表现出色⁴。此外, 在基于人类偏好的开放式评估中(如 Arena-Hard 和 AlpacaEval 2.0), DeepSeek-V3 取得了超过 86% 的胜率, 成为首个在 Arena-Hard 上突破 85% 的开源模型, 这有力地证明了其在与用户直接交互时的生成质量⁴。

4.3 社区之声: 定性优势与劣势

尽管基准测试结果光鲜亮丽, 但来自社区的真实用户反馈呈现出一种两面性。在 Reddit 等平台上, 许多开发者和程序员对 DeepSeek-V3 在编程和数学问题上的表现赞不绝口, 称其“绝对坚如磐石”, 这与基准数据高度一致²³。

然而, 当用于非编码的、更偏向通用对话或创意写作的任务时, 一些用户则表达了失望。他们报告称, 模型有时会“比 Claude 更笨”, 容易陷入重复循环, 忽略指令, 甚至产生无意义的回答²³。这种反馈的差异性暗示, DeepSeek-V3 的后训练阶段(监督微调和强化学习)可能被高度优化, 以追求在技术类基准上的卓越表现, 而这可能在一定程度上牺牲了其在更广泛的通用对话和创意任务上的能力。

表 4: 关键基准性能对比 (DeepSeek-V3 vs. 竞争者)

| 基准测试 | 任务类型 | DeepSeek-V3 | GPT-4o | Claude 3.5 Sonnet | Llama 3.1 405B |
|-----------|------|-------------|--------|-------------------|----------------|
| MMLU-Pro | 通用知识 | 81.2 | 84.1 | 83.5 | 80.1 |
| GPQA-Diam | 推理 | 68.4 | 72.3 | 70.1 | 65.2 |

| ond | | | | | |
|------------|------|-------|-------|-------|-------|
| MATH-500 | 数学 | 65.2 | 68.9 | 67.5 | 60.3 |
| HumanEval | 代码 | 82.6 | 81.9 | 82.1 | 79.5 |
| Arena-Hard | 人类偏好 | 86.2% | 88.1% | 87.5% | 82.3% |

注:数据来源于论文⁴及相关基准排行榜,可能随时间更新。

第四节 洞察与启示

DeepSeek-V3 展现出一种“尖峰式”或专业化的智能。它在技术领域的全球顶尖性能是无可否置的,但其通用能力,尤其是在需要创造力和细微情感理解的对话任务中,可能不如其顶尖的闭源对手那样稳健。这种现象的背后,很可能是在后训练阶段做出的战略性权衡。DeepSeek-AI 可能有意将其数据和计算资源集中投入到那些价值高、易于自动化评估且深受企业用户青睐的技术领域。因此,该模型更像一个专业的“技术专家”,而非一个全能的“对话伙伴”。这对企业在选择模型时具有重要启示:模型的选择应基于“适用性”,而非单一的综合评分。对于开发者或科学家而言,DeepSeek-V3 可能是最佳选择;但对于作家或市场营销人员,它可能会带来挫败感。

第五节:架构背后的建筑师:DeepSeek-AI 公司剖析

要理解这项技术飞跃,就必须了解其背后的组织。DeepSeek-AI 独特的结构、资金来源和人才战略,与其创造的产品密不可分。

5.1 新晋挑战者:起源、资金与哲学

DeepSeek-AI 于 2023 年 7 月由量化对冲基金“幻方量化”(High-Flyer)的联合创始人梁文锋创立,梁文锋同时担任两家公司的 CEO³。其最独特的方面在于其资金模式:公司几乎完

全由幻方量化自筹资金，没有引入传统的风险投资³。这一关键区别使其能够摆脱 VC 模式下对短期回报和快速“退出”的压力，从而进行更长周期的基础研究³。

在战略上，DeepSeek-AI 选择了开放权重(open-weight)的道路，以宽松的许可证发布其模型²。这一策略迅速赢得了开源社区的青睐与合作，使其成为开源生态的领导者之一，与 OpenAI 的封闭路线形成了鲜明对比¹。

5.2 人文因素: DeepSeek 的人才与研究文化分析

斯坦福大学胡佛研究所的一份深入分析报告为我们揭示了 DeepSeek 的人才构成²¹。一个惊人的发现是，其绝大多数研究人员都在中国接受教育和培训，形成了一条强大的本土人才管道。报告还指出了一个由 31 名研究人员组成的“核心团队”，他们参与了公司所有五篇基础性论文的撰写，并拥有可靠的学术记录(人均引用量超过 1500 次)，这有力地驳斥了其成功源于“无名之辈”的说法²¹。

在招聘理念上，公司强调技能而非冗长的工作经验，因此吸纳了许多来自中国顶尖大学的应届毕业生。同时，为了拓宽模型的知识基础，公司还从计算机科学以外的领域(如诗歌或高等数学)招募人才³。

第五节洞察与启示

DeepSeek-AI 的公司结构为长期的、高风险、高回报的基础研究进行了优化。创始人梁文锋在量化金融和 AI 交易算法方面的背景，为公司注入了严谨、数据驱动和着眼长远的研发文化³。来自自有对冲基金的稳定资金支持，意味着公司无需迎合外部投资者对短期财务指标的要求，可以心无旁骛地投入到像 MLA 和无损失 MoE 这样短期内可能没有直接回报，但长期来看能带来突破性效率提升的基础研究中。因此，DeepSeek-AI 与其说是一家典型的初创公司，不如说更像一个由量化交易利润资助的、专注于 AGI 的私人工业研究实验室，如贝尔实验室或施乐帕克研究中心。

从地缘政治的角度看，DeepSeek 的成功，由一支以中国本土人才为主的团队驱动²¹，是中国在基础 AI 研究领域能力迅速提升的有力信号。它挑战了美国在前沿 AI 创新领域长期以来的主导地位，并证明了中国有能力独立培养顶尖人才和开发前沿技术。

第六节：结论性分析：对全球 AI 生态系统的战略影响

本节将综合报告的所有发现，为决策者提供高层次、前瞻性的战略洞察。

6.1 挑战算力护城河：效率驱动创新的崛起

本报告的核心结论是，DeepSeek-V3 的成功证明了算法和工程的智慧可以战胜原始计算力的野蛮生长。它表明，AI 领域的“护城河”可能不再仅仅是 GPU 集群的规模，更是研究团队的质量和创新能力。这种由效率驱动的创新，一旦被开源，就可以被其他参与者迅速采纳，从而在某种程度上“民主化”了构建前沿模型的能力，降低了进入门槛²。

6.2 开放权重模型的未来与 AI 地缘政治

一个由中国开发、成本效益极高、性能顶尖的开放权重模型的出现，对全球 AI 格局具有深远影响。它极大地加速了整个开源社区的能力演进，可能比以往任何时候都更快地缩小与闭源领导者之间的差距。同时，它在美国之外建立了一个强大的 AI 发展新重心，对全球技术竞争、标准制定和供应链都将产生重大影响。

6.3 最终裁决与未来轨迹

总结而言，DeepSeek-V3 的主要成就包括：

- 效率基准：为大规模语言模型的训练效率设立了新的行业标杆。
- 技术创新：引入并验证了多项关键的架构和工程创新（MLA、无损失 MoE、FP8 训练）。
- 性能表现：在开放权重的框架内，于高价值的技术领域实现了世界一流的性能。

展望未来，DeepSeek 的技术将被竞争对手迅速研究和采纳。现有巨头如 OpenAI、Google 和 Anthropic 将面临新的压力，不仅要证明其模型的规模，更要证明其效率。未来的 AI 竞争将是一场双线战争：一条战线是规模，另一条战线是效率。DeepSeek 已经在这

第二条战线上，打响了决定性的一枪。

Works cited

1. DeepSeek pioneers a new way for AI to 'reason' - Science News Explores, accessed July 27, 2025, <https://www.snexplores.org/article/deepseek-ai-reasoning-agents>
2. DeepSeek: How a small Chinese AI company is shaking up US tech heavyweights - The University of Sydney, accessed July 27, 2025, <https://www.sydney.edu.au/news-opinion/news/2025/01/29/deepseek-ai-china-us-tech.html>
3. DeepSeek - Wikipedia, accessed July 27, 2025, <https://en.wikipedia.org/wiki/DeepSeek>
4. DeepSeek-V3 Technical Report, accessed July 27, 2025, <https://arxiv.org/pdf/2412.19437>
5. unsloth/DeepSeek-V3 - Hugging Face, accessed July 27, 2025, <https://huggingface.co/unsloth/DeepSeek-V3>
6. DeepSeek V3 vs R1: Feature, Performance & Model Comparison - PromptLayer, accessed July 27, 2025, <https://blog.promptlayer.com/deepseek-v3-vs-r1/>
7. DeepSeek V3 Model March 2025 - Lulu Yan - Medium, accessed July 27, 2025, <https://luluyan.medium.com/deepseek-v3-model-march-2025-2a7cd4594abd>
8. Understanding Multi-Head Latent Attention, accessed July 27, 2025, <https://planetbanatt.net/articles/mla.html>
9. DeepSeek-V3 Explained 1: Multi-head Latent Attention | Towards Data Science, accessed July 27, 2025, <https://towardsdatascience.com/deepseek-v3-explained-1-multi-head-latent-attention-ed6bee2a67c4/>
10. Grouped Query Attention (GQA) vs. Multi Head Attention (MHA): LLM Inference Serving Acceleration - FriendliAI, accessed July 27, 2025, <https://friendli.ai/blog/gqa-vs-mha>
11. DeepSeek + SGLang: Multi-Head Latent Attention — Blog - DataCrunch, accessed July 27, 2025, <https://datacrunch.io/blog/deepseek-sglang-multi-head-latent-attention>
12. TransMLA: Multi-Head Latent Attention Is All You Need - arXiv, accessed July 27, 2025, <https://arxiv.org/html/2502.07864v2>
13. Multi-Head Latent Attention: Benefits in Memory and Computation — Blog - DataCrunch, accessed July 27, 2025, <https://datacrunch.io/blog/multi-head-latent-attention-benefits-in-memory-and-computation>
14. Mixture of experts - Wikipedia, accessed July 27, 2025, https://en.wikipedia.org/wiki/Mixture_of_experts
15. Mixture-of-Experts: a publications timeline, with serial and distributed implementations, accessed July 27, 2025, <https://brunomaga.github.io/Mixture-of-Experts>
16. arXiv:2501.11873v2 [cs.LG] 4 Feb 2025, accessed July 27, 2025,

- <https://arxiv.org/pdf/2501.11873>
17. Auxiliary-Loss-Free Load Balancing Strategy for Mixture-of-Experts | OpenReview, accessed July 27, 2025, <https://openreview.net/forum?id=y1iU5czYpE>
 18. [2408.15664] Auxiliary-Loss-Free Load Balancing Strategy for Mixture-of-Experts - arXiv, accessed July 27, 2025, <https://arxiv.org/abs/2408.15664>
 19. Paper page - Pre-Training Curriculum for Multi-Token Prediction in Language Models, accessed July 27, 2025, <https://huggingface.co/papers/2505.22757>
 20. Deepseek made the impossible possible, that's why they are so panicked. - Reddit, accessed July 27, 2025, https://www.reddit.com/r/singularity/comments/1ic4z1f/deepseek_made_the_impossible_possible_thats_why/
 21. A Deep Peek into DeepSeek AI's Talent and Implications for US Innovation - Hoover Institution, accessed July 27, 2025, https://www.hoover.org/sites/default/files/research/docs/Zegart_DeepSeekAI_Talent_FINAL_4-21.pdf
 22. Open R1: Update #4 - Hugging Face, accessed July 27, 2025, <https://huggingface.co/blog/open-r1/update-4>
 23. Deepseek V3 is absolutely astonishing : r/LocalLLaMA - Reddit, accessed July 27, 2025, https://www.reddit.com/r/LocalLLaMA/comments/1hofvtw/deepseek_v3_is_absolutely_astonishing/
 24. DeepSeek: What You Need to Know - CSAIL Alliances - MIT, accessed July 27, 2025, <https://cap.csail.mit.edu/research/deepseek-what-you-need-know>
 25. DeepSeek - 2025 Company Profile, Team & Competitors - Tracxn, accessed July 27, 2025, https://tracxn.com/d/companies/deepseek/_1GrZ3pgoi2O-9tMSfF9ka6Sjybc1lgSZ_qQqo5k2vE
 26. DeepSeek AI: Company Overview, Founding team, Culture and DeepSeek R1 Model | by ByteBridge, accessed July 27, 2025, <https://bytebridge.medium.com/deepseek-ai-company-overview-founding-team-culture-and-deepseek-r1-model-ea87f711b4b3>
 27. A Deep Peek Into DeepSeek AI's Talent And Implications For US Innovation, accessed July 27, 2025, <https://www.hoover.org/research/deep-peek-deepseek-ais-talent-and-implications-us-innovation>