

大型语言模型多令牌预测潜力分析:原理、创新与可行性

执行摘要

本报告旨在深入分析题为“您的LLM了解未来:揭示其多令牌预测潜力”(arXiv:2507.11851)的学术论文¹。该论文致力于解决自回归大型语言模型(LLM)固有的顺序令牌生成限制,这一限制显著制约了推理速度和并行性,尤其在文本方向和语义相对确定的生成后期阶段¹。

该研究提出了一种新颖的框架,通过利用香草自回归LLM对未来令牌的内在知识,实现了多个后续令牌的同时预测¹。其核心创新包括:(1)一种掩码输入公式,用于从共同前缀联合预测多个未来令牌¹;(2)一种门控LoRA(低秩适应)公式,在保留原始LLM功能的同时,使其具备多令牌预测能力¹;(3)一个轻量级、可学习的采样器¹;(4)辅助的一致性损失,以增强联合生成令牌的连贯性和准确性¹;以及(5)一种推测性生成策略,能够以二次方速度扩展未来令牌,同时保持高保真度¹。

通过在预训练模型上进行监督微调,该方法取得了显著的加速¹。例如,在代码和数学生成任务中,速度提升近5倍¹;在通用聊天和知识任务中,速度提升近2.5倍¹。值得注意的是,这些性能提升是在

不损失任何生成质量的前提下实现的¹。

这项工作代表了LLM部署效率、实时性和成本效益方面的重要进展,对各种人工智能应用具有广泛影响,并有望降低其环境足迹⁷。

1. 引言:LLM推理的挑战

近年来,大型语言模型(LLM)在人工智能领域取得了突破性进展,其能力已从编程辅助扩展到提供法律和健康咨询⁹。这些模型的强大能力主要得益于大规模文本数据的可用性以及自回归训练的有效性²。LLM通过处理海量语料库,获得了对人类语言中固有的语法、语义和本体论的强大预测能力¹⁰。在这一过程中,文本首先被分解为更小的组成部分,即“令

牌”，这些令牌随后被转换为整数ID并存储在数组中，从而使LLM能够理解输入并生成适当的响应¹¹。

然而，LLM的自回归生成范式，即模型一次生成一个令牌，并且每个后续令牌的预测都依赖于所有先前的令牌，构成了其推理过程中的一个根本性瓶颈¹。这种顺序性从根本上限制了推理速度和并行化能力²，导致在生成长篇输出时出现高延迟和显著的计算成本⁴。这种限制在生成后期阶段尤为明显，此时文本的方向和语义通常已相对确定，这暗示了在预测可预见令牌时存在计算资源的浪费¹。标准自回归模型在计算下一个符号的概率时仅执行多项式时间计算，这限制了它们建模难以计算下一个符号概率的分布的能力¹³。

针对这些固有限制，论文“您的LLM了解未来：揭示其多令牌预测潜力”（arXiv:2507.11851）提出了一种直接的解决方案¹。该研究旨在通过利用LLM对未来令牌的内在知识，实现多个后续令牌的同时预测，从而在不损害生成质量的前提下显著提升推理速度¹。

该研究直接解决了自回归LLM的核心架构限制，即顺序生成过程，这是在延迟敏感型应用中部署LLM的一个根本性挑战⁹。该论文的标题和摘要——“您的LLM了解未来：揭示其多令牌预测潜力”以及“利用香草自回归语言模型对未来令牌的内在知识”²——表明了一个核心假设：LLM尽管其输出是顺序的，但其内部可能已经拥有对即将到来序列的更丰富、多令牌的理解¹。这意味着挑战不在于

创造这种知识，而在于以并行方式提取和实现它¹。如果LLM在预测下一个令牌时，其内部表征已经包含了关于多个可能未来令牌及其关系的复杂信息，那么顺序生成就仅仅是一种

输出约束，而非知识限制¹。论文的目标正是要绕过这种输出约束¹。这种观点与人类认知过程相呼应，例如在表达之前在脑海中形成完整的句子⁹。如果这一假设成立，则意味着LLM比其当前的推理机制所允许的更为强大，解锁这一潜力可以在不从头开始重新训练大型基础模型的情况下，带来显著的效率提升¹。

2. 学科基础：理解LLM机制

为了全面理解所提出的多令牌预测框架，有必要回顾LLM的基本机制及其现有加速技术。

令牌化及其在LLM中的作用

令牌化是文本处理的关键第一步，它将原始文本分解为模型可以理解的更小、离散的单元，

即令牌¹¹。这些令牌随后被转换为整数ID，并存储在一个数组中，这些ID指向模型的词汇表，从而使LLM能够处理输入并生成相应的响应¹¹。值得注意的是，不同模型和语言之间的令牌化效率差异很大¹⁵。例如，Llama 3的令牌化器在处理代码时比Llama 2的效率高出15%¹⁵。这种效率差异直接影响了实际的“每秒令牌数”(TPS)，进而影响了用户感知的延迟¹⁵。因此，在比较不同LLM的性能时，必须考虑令牌化器的效率，因为原始的TPS数据可能无法准确反映真实世界的速度提升¹⁵。

自回归解码原理

大多数LLM，特别是像GPT这样的模型，都是基于自回归原理进行预训练的，即它们被训练来预测给定先前上下文的下一个令牌¹⁰。在生成过程中，模型一次只预测一个令牌，并将该令牌追加到序列中，然后重复这个过程，直到生成完成⁴。这种顺序生成方式意味着每个令牌的生成都需要模型进行一次完整的正向传播⁴。这种计算模式虽然在训练时非常有效，但在推理时却成为一个主要的效率瓶颈，尤其是在生成长文本时⁴。

现有推理加速技术

为了缓解自回归生成带来的速度限制，研究人员开发了多种推理加速技术：

推测性解码

推测性解码是一种旨在在不牺牲输出质量的前提下加速LLM推理的流行方法⁴。其核心机制是使用一个更小、更快的“草稿模型”快速生成多个令牌，然后由一个更大、更准确的“目标模型”对这些令牌进行验证⁴。这种方法显著减少了每个输出令牌所需的计算周期¹⁷。尽管推测性解码能提供加速，但它仍然依赖于自回归生成进行最终验证²。

推测性解码面临一些挑战：

- 如果草稿模型量化(降低精度)，可能会生成质量较低的令牌，导致更多的拒绝和解码速度变慢⁴。
- 量化目标模型可能由于反量化例程而引入额外的延迟⁴。
- 硬件限制有时会抵消预期的性能提升⁴。

- 早期推测性解码方法的一个主要实际障碍是需要匹配词汇表, 但最近的进展, 如SLM和TLI, 已经有效地克服了这一限制, 提供了无损加速, 并已集成到Hugging Face Transformers等主流工具中⁵。
- 推测性解码的效率受“草稿置信阈值”(τ)和“辅助令牌数量”(k)等参数的影响, 这些参数决定了草稿模型的提案质量和数量⁴。

雅可比解码与一致性模型

雅可比解码是一种并行解码方法, 它首先随机猜测序列中的N个后续令牌, 然后将这些N个令牌连同提示一起输入LLM, 迭代地更新自身, 直到N个令牌序列稳定并达到固定点⁹。然而, 实践中香草雅可比解码相对于自回归解码仅显示出边际加速(平均1.5倍), 因为自回归训练的LLM在先行令牌不正确时很少能产生正确令牌⁹。

为了解决这个问题, 研究人员提出了一致性大型语言模型(**CLLM**), 这是一种新的并行解码器系列⁹。CLLM通过微调预训练LLM来学习将雅可比轨迹上的任何点一致地映射到固定点, 从而实现高效的N令牌序列并行解码⁹。CLLM的训练目标类似于扩散模型中的一致性模型, 它联合优化了

一致性损失(用于多令牌预测)和传统的自回归损失(用于防止模型偏离目标LLM的分布, 从而保持生成质量)⁹。

所分析的论文将自身定位为在现有推理加速技术, 特别是推测性解码的背景下, 通过声称在不损失任何质量的情况下实现加速, 并通过一种新颖、更直接的多令牌预测机制而非草稿-验证循环来实现¹。现有推测性解码本质上依赖于大型模型对草稿模型提出的令牌进行验证⁴。相比之下, 本论文的方法似乎训练

原始LLM直接预测多个未来令牌¹。这表明了一种更集成且可能更健壮的多令牌生成方法, 减少了与独立草稿模型相关的开销和潜在的拒绝率⁴。如果原始LLM本身经过微调以直接预测多个令牌, 它将绕过对独立草稿模型的需求以及验证和潜在回滚相关的开销⁴。这可能导致更稳定和一致的多令牌生成, 因为“验证器”本质上已融入生成过程本身¹。

3. 所提出框架的核心原理与方法论

论文提出了一种新颖的框架, 旨在利用香草自回归大型语言模型(LLM)对未来令牌的内在

知识, 从而实现多个后续令牌的同时预测¹。该框架的整体架构涉及将一个增强序列输入解码器, 以生成标准下一个令牌预测(NTP)和掩码令牌预测(MTP)的潜在表示⁶。该方法通过以下关键创新协同工作:

3.1. 掩码输入公式

为了实现联合预测, 该方法引入了独特的掩码令牌¹。具体而言, 在输入序列

$X = [x_1, \dots, x_n]$ 的末尾附加 k 个唯一的掩码令牌 $[m_1, \dots, m_k]$, 从而形成一个增强序列 $X_m = [x_1, \dots, x_n, m_1, \dots, m_k]$ ⁶。这些掩码令牌的表示被生成为随机向量, 并添加到模型的嵌入表中⁶。模型被训练以直接从共同的前缀预测这些掩码令牌²。在推理阶段,

X_m 被输入解码器, 网络为NTP令牌和MTP令牌生成潜在表示⁶。这种方法使得多个未来令牌能够被联合预测, 超越了传统掩码语言模型(MLM)通常仅限于单个令牌预测的限制¹⁶。

3.2. 门控LoRA公式

此项创新旨在使LLM具备多令牌预测能力的同时, 保留其原始功能¹。它承诺不降低生成质量²。LoRA(低秩适应)是一种高效的微调技术, 通过在冻结原始模型权重的基础上添加轻量级的低秩矩阵来适应大型模型到新上下文¹⁷。这种方法显著减少了可训练参数的数量(例如, GPT-3的1750亿参数可减少到约1800万), 从而大幅降低了GPU内存需求²¹。

“门控”方面表明存在一种机制, 用于控制或调节这些LoRA适应的应用, 以确保基础模型的完整性¹⁸。这与¹⁸中提到的用于组合多个LoRA的“门控网络”类似, 其作用是帮助维持模型的生成能力, 防止因直接融合而导致输出混乱¹⁸。在该框架中, 主模型被冻结, 并使用秩为128的门控LoRA层进行增强⁵。

3.3. 轻量级、可学习的采样器

该框架引入了一个轻量级、可学习的采样器模块, 具体为一个两层MLP(多层感知器)基础的采样器头¹。其功能是从预测的未来令牌中生成连贯的序列⁵。在生成过程中, 第一个(NTP)令牌是自回归生成的, 而其余的(MTP)令牌则由采样器模块顺序生成, 并以其潜在表

示和先前采样的令牌为条件⁶。

3.4. 辅助训练损失(一致性损失)

论文提出使用一致性损失来增强联合生成令牌的连贯性和准确性¹。该损失的目标是最小化掩码令牌预测(MTP)与每个令牌对应的下一个令牌预测(NTP)之间的距离²。这有助于使推测性草稿器与验证模型对齐¹。

这种一致性训练与一致性大型语言模型(CLLM)的概念相符,后者也使用一致性损失来实现并行解码并保持生成质量,通常与传统的自回归(AR)损失结合使用⁹。总损失函数

$L(\theta) = L_{\text{consistency}} + w * L_{\text{AR}}$ 表明了一个双重目标:既要实现并行预测,又要防止模型偏离原始自回归分布,从而维护生成质量⁹。

3.5. 推测性生成策略

该框架采用了一种推测性生成策略,能够在保持高保真度的同时,以二次方的速度扩展未来令牌¹。这与传统推测性解码通常以固定

k个令牌进行扩展的方式有所不同⁴。通过掩码输入和一致性训练,这种方法似乎将“推测”直接集成到经过微调的LLM中¹。

所提出的方法论是一个多组件系统,而非单一技巧¹。其五项创新高度相互依赖,形成了一个协同工作的系统¹。掩码输入公式提供了并行预测的

机制¹;门控LoRA提供了在不损害基础模型的情况下进行

高效适应的能力¹;轻量级采样器确保了并行预测的

连贯性¹;一致性损失提供了训练

信号,以使并行预测与模型固有的自回归知识对齐,从而使推测性生成策略既健壮又保持质量¹;最后,推测性生成策略利用这种一致性实现高效的扩展¹。每个组件都解决了多令牌生成中的特定挑战,它们的组合是实现所报告性能的关键¹。

尽管LoRA或掩码输入等单个组件已经存在¹⁶，但该方法的

新颖之处在于它们的特定组合、LoRA的“门控”方面以及为多令牌预测量身定制的“一致性损失”¹。这表明对如何修改自回归模型以使其表现得像并行解码器，同时不从根本上改变其核心架构或牺牲其已学习知识的复杂理解¹。这与可能需要更显著架构更改或依赖外部草稿模型的方法形成了对比⁴。

表1: 关键创新总结

创新	描述	主要优势/目的	相关片段
掩码输入公式	通过在输入末尾附加掩码令牌，从共同前缀联合预测多个未来令牌。	实现多个令牌的同时预测，超越了顺序生成模式。	1
门控LoRA公式	一种特殊的低秩适应(LoRA)，在使LLM具备多令牌预测能力的同时，保留其原始功能。	以最小的参数变化高效地使LLM具备多令牌预测能力，防止基础模型质量下降。	1
轻量级、可学习的采样器	一个基于两层MLP的模块，用于从预测的未来令牌生成连贯的序列。	确保联合生成的多令牌输出的质量和连贯性。	1
辅助一致性损失	最小化掩码令牌预测与相应下一个令牌预测之间的距离。	增强联合生成令牌的准确性和连贯性，使多令牌预测与模型固有的自回归知识对齐。	1
推测性生成策略	在保持高保真度的同时，以二次方速度扩展未来令牌。	通过一次预测更长的序列实现显著加速，最大化并行化潜力。	1

5. 实验结果与性能分析

该研究通过在预训练模型上进行监督微调，展示了所提出框架的显著性能提升¹。

加速指标

该方法在不同任务中取得了令人印象深刻的加速效果：

- 代码和数学生成：速度提升近5倍¹。
- 通用聊天和知识任务：速度提升近2.5倍¹。
- 总体范围：根据任务和插入掩码的数量，速度提升范围为1.5倍至5.2倍⁵。

质量保持

至关重要的是，这些速度提升是在不损失任何生成质量的前提下实现的¹。这一特性是该方法相对于其他可能以准确性为代价来换取速度的加速技术（如某些量化方法）的显著优势⁴。

微调过程与资源

该方法采用监督微调在预训练模型上进行¹。实验设置的具体细节如下⁵：

- 模型微调了50,000次迭代⁵。
- 使用了8块NVIDIA A100 GPU⁵。
- 每块GPU的批处理大小为1⁵。
- 采用了AdamW优化器，学习率平坦，并伴随5,000次迭代的热身阶段⁵。
- 主模型被冻结，并用秩为128的门控LoRA层进行增强⁵。
- 一个两层MLP模块被用作采样器模块⁵。

损失评估

对一致性损失（在⁵中被称为LCM损失）的影响进行了评估，以确保模型预测与底层自回归模型预测之间的一致性⁵。

实验结果有力地支持了该论文关于在不降低质量的情况下实现大幅加速的主张，使其在实际部署中极具吸引力¹。不同任务（代码/数学5倍加速，聊天2.5倍加速）的速度提升差异表明，该方法的效率增益并非在所有任务中都均匀分布¹。这暗示了某些领域（如代码或数学）固有的可预测性或结构规律性，使得比开放式、多样化的领域（如通用聊天）能够进行更激进的多令牌预测¹⁵。这种观察对于实际应用至关重要，因为它指导了该方法在何处能产生最显著的投资回报¹⁵。代码和数学表达式通常遵循更严格的语法规则、可预测的模式，并且与自然语言聊天相比，其词汇或结构更为受限¹⁵。因此，当未来更具确定性或受规则约束时，“对未来令牌的内在知识”²更有可能被强化并更容易“揭示”¹。这意味着在这些领域，模型可以更高置信度地提前“了解”更多令牌¹。对于部署而言，这意味着该方法特别适用于代码补全、定理证明或结构化数据生成等任务，在这些任务中，加速效果最大化¹。对于通用对话式AI，虽然仍有益，但收益更为适中¹。这也为未来研究基于当前生成上下文的熵或可预测性进行自适应多令牌预测提供了方向¹。

表2: 不同任务的性能增益

任务领域	报告的加速因子	质量影响	相关片段
代码生成	近5倍	无质量损失	1
数学生成	近5倍	无质量损失	1
通用聊天	近2.5倍	无质量损失	1
知识任务	近2.5倍	无质量损失	1
总体(范围)	1.5倍至5.2倍	无质量损失	5

6. 未来应用可能性

所提出的多令牌预测框架在不牺牲质量的前提下显著提升了LLM的推理速度，这为广泛的未来应用开启了新的可能性，并有望改变LLM在各个行业的部署方式¹。

- **增强实时对话式AI：**通用聊天任务中近2.5倍的生成速度提升¹使得聊天机器人和虚拟助手能够提供更流畅、更灵敏的交互体验，有效降低了人机交互中的感知延迟²⁰。这可以显著改善客户服务、教育工具和个人AI伴侣的用户体验²³。

- 加速代码生成与调试：代码生成任务中近5倍的加速¹对开发工具、代码自动补全和自动化调试建议具有深远影响¹。这将为软件工程师带来可观的生产力提升，并加速软件开发生命周期¹。
- 快速内容创作与摘要：更快的文本生成能力使得文章、报告、营销文案的起草以及长文档的摘要变得更加迅速，从而提高内容创作者和分析师的工作效率²⁰。
- 改进数学推理与问题解决：数学任务中5倍的加速¹表明AI系统在协助科学研究、复杂计算和自动化问题解决方面具有巨大潜力¹。
- 在延迟敏感环境中的部署：在不损失质量的情况下实现加速的能力，使得LLM在边缘设备、嵌入式系统或对即时响应要求极高的应用(如游戏、实时翻译或自动驾驶系统)中变得更加可行¹⁷。
- 降低LLM服务成本：更快的推理速度意味着每单位生成内容所需的计算资源(GPU小时)更少⁴，从而降低了LLM提供商和用户的运营成本²¹。

该技术的核心优势在于其在加速生成的同时保持质量，这使得其在各个行业(从软件开发到内容创作和客户服务)都具有广泛的实际应用潜力¹。通过显著提高LLM推理的速度和资源效率(特别是通过LoRA微调的益处¹⁷)，这项技术可以降低部署复杂LLM应用的门槛²¹。LLM虽然功能强大，但运行成本高昂，尤其是在高吞吐量或实时任务中⁴。该论文提供了显著的加速¹，并利用LoRA进行高效微调¹⁷。推理成本的降低(由于速度提升)和适应成本的降低(由于LoRA)意味着小型企业、独立开发者或预算有限的组织现在可以负担得起将LLM集成并定制到其特定需求中²¹。这将使LLM从大型科技公司的“奢侈品”转变为更易于访问的工具，从而促进各行各业的创新和更广泛的应用²¹。这与⁷中讨论的“微服务思维”相契合⁷。

7. 可行性分析

7.1. 技术可行性

所提出的框架在技术上具有高度可行性，因为它利用了现有且成熟的技术¹。掩码输入、LoRA、

Works cited

1. Your LLM Knows the Future: Uncovering Its Multi-Token Prediction Potential - arXiv, accessed July 26, 2025, <https://arxiv.org/abs/2507.11851>

2. (PDF) Your LLM Knows the Future: Uncovering Its Multi-Token Prediction Potential, accessed July 26, 2025, https://www.researchgate.net/publication/393771091_Your_LLM_Knows_the_Future_Uncovering_Its_Multi-Token_Prediction_Potential
3. Computer Science - arXiv, accessed July 26, 2025, <https://www.arxiv.org/list/cs/pastweek?skip=723&show=1000>
4. Optimizing LLM Inference with Speculative Decoding and Quantization - Medium, accessed July 26, 2025, <https://medium.com/@ns3888/optimizing-llm-inference-with-speculative-decoding-and-quantization-ccfb491e67f5>
5. Your LLM Knows the Future: Uncovering Its Multi-Token Prediction Potential - ChatPaper, accessed July 26, 2025, <https://chatpaper.com/paper/164495>
6. Your LLM Knows the Future: Uncovering Its Multi-Token Prediction Potential - arXiv, accessed July 26, 2025, <https://arxiv.org/html/2507.11851v1>
7. Fine-tune an LLM: Why, when, and how - Builder.io, accessed July 26, 2025, <https://www.builder.io/blog/fine-tune-llm>
8. Unveiling Environmental Impacts of Large Language Model Serving: A Functional Unit View, accessed July 26, 2025, https://www.researchgate.net/publication/389090325_Unveiling_Environmental_Impacts_of_Large_Language_Model_Serving_A_Functional_Unit_View
9. Consistency Large Language Models: A Family of Efficient Parallel Decoders, accessed July 26, 2025, <https://hao-ai-lab.github.io/blogs/cllm/>
10. Large language model - Wikipedia, accessed July 26, 2025, https://en.wikipedia.org/wiki/Large_language_model
11. airbyte.com, accessed July 26, 2025, <https://airbyte.com/data-engineering-resources/llm-tokenization#:~:text=Tokenization%20breaks%20down%20text%20into,inputs%20and%20produce%20appropriate%20responses.>
12. Introduction to LLM Tokenization - Airbyte, accessed July 26, 2025, <https://airbyte.com/data-engineering-resources/llm-tokenization>
13. Limitations of Autoregressive Models and Their Alternatives - ACL Anthology, accessed July 26, 2025, <https://aclanthology.org/2021.naacl-main.405/>
14. ALTo: Adaptive-Length Tokenizer for Autoregressive Mask Generation | AI Research Paper Details - AIModels.fyi, accessed July 26, 2025, <https://www.aimodels.fyi/papers/arxiv/alto-adaptive-length-tokenizer-autoregressive-mask-generation>
15. Comparing tokens per second across LLMs | Baseten Blog, accessed July 26, 2025, <https://www.baseten.co/blog/comparing-tokens-per-second-across-llms/>
16. Simple and effective multi-token completion from masked language models - Amazon Science, accessed July 26, 2025, <https://www.amazon.science/publications/simple-and-effective-multi-token-completion-from-masked-language-models>
17. Intel and Weizmann Institute Speed AI with Speculative Decoding Advance, accessed July 26, 2025, <https://newsroom.intel.com/artificial-intelligence/intel-weizmann-institute-speed->

[ai-with-speculative-decoding-advance](#)

18. Mixture of LoRA Experts - OpenReview, accessed July 26, 2025, <https://openreview.net/forum?id=uWvKBCYh4S>
19. Audio Overview: Accelerating LLM Inference with Lossless Speculative Decoding (read), accessed July 26, 2025, <https://www.youtube.com/watch?v=wOqwQK9oW-k>
20. Unlocking Long-Context Potential: Advances in Speculative Decoding for LLMs, accessed July 26, 2025, https://dev.to/gilles_hamelink_ea9ff7d93/unlocking-long-context-potential-advances-in-speculative-decoding-for-llms-53l8
21. What is LoRA (Low-Rank Adaption)? - IBM, accessed July 26, 2025, <https://www.ibm.com/think/topics/lora>
22. Low Rank Adaptation: Reduce the Cost of Model Fine-Tuning | Coursera, accessed July 26, 2025, <https://www.coursera.org/articles/low-rank-adaptation>
23. Fine-tuning large language models (LLMs) in 2025 - SuperAnnotate, accessed July 26, 2025, <https://www.superannotate.com/blog/llm-fine-tuning>